

Data science e data mining

Sintesi ragionata per la prova orale

Concorso RIPAM 294 unità — Codice 02, Area dei funzionari — prova orale del 27 novembre 2026

Questa dispensa nasce dalla scheda «**Elementi di data science e data mining**» (Simone, edizione RIPAM 294) caricata su Drive, letta integralmente. La scheda è però **breve** — **sei pagine** — e copre soltanto l'impianto metodologico: definizioni, processo KDD, modello CRISP-DM. Per una prova orale su una materia del bando questo non basta: la commissione, davanti a un candidato dell'area dei funzionari, chiede quasi sempre **che cosa fa concretamente un algoritmo, come si valuta se funziona, e che cosa cambia quando i dati sono quelli di una pubblica amministrazione**.

Ho quindi costruito la dispensa su **due livelli, e li tengo visivamente distinti**:

- le **Parti I-III** sono la scheda, riportata integralmente e resa discorsiva: è il nucleo che devi conoscere alla lettera perché è il materiale ufficiale del concorso;
- le **Parti IV-X** sono **integrazione mia**, necessaria e segnalata come tale: i dati e la loro qualità, il pre-processing in dettaglio, la tassonomia del machine learning, gli algoritmi fondamentali, le metriche di valutazione, e soprattutto il **capitolo su dati e algoritmi nella P.A. italiana**, che è quello in cui un funzionario RIPAM deve saper parlare meglio di un informatico.

Sul livello di formalizzazione. Ho applicato qui la stessa regola che mi hai dato per econometria e statistica: **niente derivazioni, niente dimostrazioni**. Le poche formule presenti sono raccolte in un riquadro alla fine («**Le dieci formule che vale la pena sapere**») e sono tutte del tipo che si scrive in tre secondi alla lavagna: le metriche di classificazione, l'errore quadratico medio, la distanza euclidea. Valuta tu quali memorizzare: nessuna di esse è indispensabile per rispondere bene, tutte e dieci insieme fanno una risposta eccellente.

Parte I — Che cos'è la data science

1. La definizione

La **data science** è una **disciplina trasversale a molteplici settori**, che integra **statistica, programmazione, machine learning e conoscenze di dominio** per trasformare **dati grezzi in informazioni utili**. Supporta i processi decisionali, anche **predittivi**, attraverso l'analisi di dataset complessi — tabelle SQL strutturate, ma anche testi e immagini non strutturati. Identificando **pattern nascosti**, automatizza e ottimizza l'intero processo di analisi per estrarre informazioni immediatamente utilizzabili.

Conviene fermarsi sui **quattro ingredienti**, perché la definizione regge o cade su di essi:

Ingrediente	Che cosa porta
Statistica	il rigore inferenziale: sapere quando un pattern è reale e quando è rumore
Programmazione	la capacità operativa: manipolare volumi che nessun foglio di calcolo regge
Machine learning	la capacità predittiva: imparare dai dati una regola non scritta a priori
Conoscenza di dominio	il senso: sapere quali domande valga la pena porre e quali risposte siano plausibili

La frase da dire all'orale. «La data science non è statistica con il computer, né informatica applicata ai numeri: è la disciplina che **tiene insieme il rigore statistico, la potenza computazionale e la conoscenza del dominio** per trasformare dati grezzi in decisioni. Il quarto ingrediente — la conoscenza di dominio — è quello che più spesso viene dimenticato ed è quello che distingue un'analisi utile da un'analisi formalmente corretta ma priva di senso.»

2. Un po' di storia

La scheda ricostruisce una cronologia precisa, e vale la pena saperla raccontare perché mostra che la materia ha una genealogia e non è nata con ChatGPT.

- **Anni '60** — **John Tukey** descrive l'**analisi dei dati come campo autonomo**, distinto dalla statistica tradizionale, enfatizzando l'**esplorazione empirica** su grandi dataset;
- **1974** — **Peter Naur** propone formalmente il termine *data science*, come evoluzione della «**datalogy**», per integrare informatica e analisi dei dati;
- **anni '80** — l'esplosione dei **database relazionali** e i primi sistemi computazionali potenti introducono il **Knowledge Discovery in Databases (KDD)** e il **data mining, formalizzati nel 1996 da Fayyad**: sono le basi pratiche della data science moderna;
- **1990-2000** — il termine si consolida in ambito informatico; nel **2001 William S. Cleveland** pubblica «**Data Science: An Action Plan**», proponendola come **espansione della statistica** verso machine learning e deep learning;
- **dopo il 2010** — il vero *boom*, con **big data, cloud computing e social media** che generano volumi esponenziali di dati. Oggi la disciplina integra statistica, intelligenza artificiale, machine learning e deep learning.

Il punto che rende interessante la cronologia. Tukey nel 1960 e Cleveland nel 2001 dicono, a quarant'anni di distanza, la stessa cosa: **la statistica accademica è troppo stretta per i dati che abbiamo**. La data science non nasce dall'informatica che invade la statistica, nasce **dalla statistica che chiede di allargarsi**. Dirlo all'orale è un modo elegante di mostrare che hai capito la materia e non solo la scheda.

3. Data science, data mining e KDD a confronto

Sono concetti **correlati ma distinti**, e confonderli è l'errore più frequente.

- la **data science** è un **campo ampio e moderno**: copre l'intero ciclo di vita dei dati, dalla definizione degli obiettivi aziendali allo sviluppo e monitoraggio continuo delle soluzioni. Si concentra su **previsioni precise, automazioni intelligenti e comunicazione efficace dei risultati**, per generare valore concreto;
- il **KDD** è un **processo specifico e tecnico**, iterativo, finalizzato all'**estrazione di conoscenza da database strutturati** attraverso fasi precise;
- il **data mining** è la **fase centrale del KDD**: attraverso l'applicazione di algoritmi specifici consente di individuare **pattern o relazioni nascoste** nei dati.

La data science **integra il KDD come struttura metodologica** nel proprio flusso di lavoro, con il data mining come elemento chiave — **circa il 20% del tempo totale** — contestualizzandolo in soluzioni complete che includono obiettivi aziendali, implementazione pratica e iterazioni continue.

Il dato del 20% è una gemma da usare all'orale. Significa che **quattro quinti del lavoro di un data scientist non sono l'algoritmo**: sono capire il problema, procurarsi i dati, pulirli, e poi validare e comunicare i risultati. È esattamente il contrario dell'immagine popolare della disciplina, ed è la cosa che un'amministrazione deve sapere prima di avviare un progetto: **se il budget prevede solo il modello, il progetto fallirà.**

Lo schema delle inclusioni, che conviene saper disegnare:

Intelligenza artificiale $\supset$ Machine learning $\supset$ Deep learning Data science $\supset$ KDD $\supset$ Data mining (→ che usa algoritmi di machine learning)

Non sono due gerarchie separate: si intersecano. Il **data mining** è il punto in cui il processo KDD **attinge** alla cassetta degli attrezzi del machine learning; la **data science** è il contenitore più ampio, perché aggiunge ciò che né il KDD né il ML contengono — **gli obiettivi, il valore, la messa in produzione e la comunicazione.**

Parte II — Il processo KDD

4. La struttura

Il processo KDD si articola in **cinque fasi interconnesse e iterabili**, progettate per convertire dati grezzi in **conoscenza concreta e immediatamente applicabile**. Attraverso un approccio **sistematico ma non lineare**, integra **feedback continui** che permettono raffinamenti progressivi, garantendo una **pulizia graduale dei dati** e la scoperta di risultati affidabili, pronti per l'uso diretto in contesti operativi reali.

Sottolinea sempre l'iteratività. Il KDD non è una catena di montaggio: è un ciclo in cui ogni fase può rimandare alle precedenti. Chi lo descrive come una sequenza lineare mostra di averlo letto ma non praticato.

5. Le cinque fasi

5.1 Selezione dei dati

Prevede l'**identificazione e l'estrazione selettiva** dei dati da fonti diversificate. Si selezionano **attributi rilevanti** e **campioni rappresentativi** mediante **query strutturate** o **campionamento probabilistico**, in coerenza con gli obiettivi prefissati, **minimizzando bias** e ottimizzando le analisi successive.

Il rischio nascosto. È qui che si annidano i *selection bias*: se il campione non è rappresentativo, nessun algoritmo successivo potrà rimediare. È il motivo per cui la scheda insiste sul **campionamento probabilistico** — l'unico che consente di quantificare l'errore.

5.2 Pulizia e integrazione (*preprocessing*)

Si agisce sulla **qualità dei dati grezzi**, che spesso risultano imperfetti, per renderli uniformi e adatti alle fasi successive. Quattro operazioni:

- **rimozione degli outlier**: identificare e rimuovere **valori anomali estremi** che distorcono l'analisi;
- **riempimento dei dati mancanti**: sostituire i valori mancanti per completare il dataset, usando **media o mediana** per i casi semplici, oppure **algoritmi di machine learning come il k-nearest neighbors** per preservare relazioni complesse che le medie globali cancellerebbero;
- **eliminazione dei duplicati**: trovare e cancellare righe identiche, evitando **ridondanze che gonfiano i dati** e causano risultati sbilanciati;
- **integrazione da fonti diverse**: combinare informazioni da origini multiple (database aziendali, registri operativi, file esterni) in un **unico dataset uniforme**.

La distinzione che fa la differenza sull'imputazione. Riempire un valore mancante con la **media** è semplice ma **distrugge la struttura di correlazione**: tutti i valori mancanti diventano identici, e la varianza si riduce artificialmente. Il **k-NN** guarda invece i «vicini» di quel record e imputa un valore coerente con essi, **preservando le relazioni fra variabili**. È esattamente la ragione che la scheda dà, ed è una risposta che colpisce perché mostra che hai capito *perché* la tecnica sofisticata esiste.

5.3 Trasformazione dei dati

Si adatta il dataset alle **specifiche degli algoritmi**, attraverso:

- **normalizzazione** (scale **Min-Max** o **Z-score**);
- **creazione di variabili derivate** (*feature engineering*);
- **discretizzazione** (suddivisione dei dati in intervalli);
- **riduzione dimensionale** (metodi come la **PCA**).

Tali interventi **semplificano i dati e li rendono più veloci da elaborare**, preparandoli per le fasi successive.

5.4 Data mining

È la **fase centrale**: applicazione di algoritmi avanzati — **supervisionati e non supervisionati** — per identificare pattern nascosti. Le tecniche principali indicate dalla scheda:

Tecnica	Che cosa fa
Clustering	raggruppa dati simili, rappresentandoli in gruppi, attraverso algoritmi come il K-Means
Classificazione	assegna automaticamente i dati a categorie predefinite , sulla base delle loro caratteristiche
Regressione	stima valori numerici futuri o mancanti, attraverso relazioni matematiche fra variabili
Sintesi	crea descrizioni compatte dei dati, attraverso regole riassuntive o viste multidimensionali
Modellazione delle dipendenze	scopre relazioni significative fra variabili (es. reti bayesiane per probabilità condizionali)
Rilevamento anomalie	identifica cambiamenti significativi o deviazioni rispetto a valori storici o standard

La linea di faglia da tenere a mente: *clustering* e *rilevamento anomalie* sono **non supervisionati** (nessuna etichetta nota in partenza); *classificazione* e *regressione* sono **supervisionati** (si impara da esempi già etichettati). È la distinzione più probabile in assoluto in una domanda d'orale su questa materia.

5.5 Valutazione e presentazione dei pattern

Fase conclusiva: si **valida l'affidabilità dei risultati** emersi, impiegando **metriche quantitative** — accuratezza, precisione/riciamo e **F1-score** per dataset sbilanciati, **coefficiente di silhouette** per i raggruppamenti — integrate da **test statistici (p-value)**. I risultati vengono poi **confrontati con la conoscenza di un esperto del dominio** per verificarne l'utilità pratica.

Non saltare l'ultimo passaggio. La validazione **non è solo statistica**: la scheda è esplicita nel richiedere il confronto con l'**esperto di dominio**. Un pattern statisticamente significativo ma privo di senso sostantivo è un artefatto, non una scoperta. In una pubblica amministrazione questo si traduce in una regola operativa: **nessun modello va in produzione senza la validazione dell'ufficio che conosce il fenomeno**.

6. I sei passi operativi del data mining

Il data mining è la **quarta fase** del KDD: i dati, già puliti e trasformati, vengono analizzati per far emergere relazioni e schemi nascosti che l'occhio umano non coglierebbe. È il **momento operativo vero e proprio**, in cui gli algoritmi «scavano» (*mining*) nel dataset per estrarre **conoscenza grezza**: i risultati **non sono ancora pronti per l'uso pratico** — richiedono la fase finale di valutazione — ma costituiscono il cuore dell'intero flusso.

1. Preparazione del dataset. Si scinde il dataset in due insiemi complementari: il **training set**, di norma **circa l'80%** dei dati, dedicato all'apprendimento dei modelli; il **test set**, circa il **20%**, utilizzato per **valutazioni indipendenti**. Per la suddivisione si adottano tecniche come lo **stratified sampling**, che **preserva le proporzioni delle classi** nei due insiemi, oppure lo **split temporale** per dati cronologici. Questo approccio **previene l'overfitting** e garantisce una rappresentazione fedele della popolazione.

Perché lo split temporale per i dati cronologici. Se i dati hanno un ordine nel tempo, mescolarli a caso significa **addestrare il modello sul futuro per prevedere il passato**: una perdita di informazione dal futuro (*data leakage*) che gonfia artificialmente le prestazioni e crolla in produzione. È un errore comunissimo e citarlo fa un'ottima impressione.

2. Selezione degli algoritmi. Si valutano e scelgono categorie appropriate al contesto: **clustering** per raggruppamenti naturali, **classificazione** per analisi categorica, **regressione** per stime quantitative, **algoritmi di associazione** per estrarre regole di co-occorrenza. **Si confrontano più algoritmi** per selezionare quello più adatto all'obiettivo specifico.

3. Addestramento dei modelli. Gli algoritmi elaborano ripetutamente i dati del training set attraverso tecniche di **ottimizzazione progressive**, combinando diversi approcci (**metodi ensemble**) per aumentare affidabilità e precisione.

4. Validazione incrociata. I modelli vengono testati sistematicamente su **diverse porzioni del dataset**, suddividendo i dati in **sottogruppi multipli** per valutare ripetutamente la capacità di **generalizzare su dati non visti**. Il processo identifica vulnerabilità come l'**overfitting**.

5. Ottimizzazione dei parametri. Si regolano finemente le **configurazioni chiave** degli algoritmi tramite ricerche sistematiche o esplorative, confrontando varianti multiple per identificare la configurazione ottimale (*hyperparameter tuning*).

6. Generazione dei pattern. I risultati preliminari vengono trasformati in **strutture interpretabili**, attraverso analisi di qualità e **prioritizzazione delle variabili più influenti**, preparando *output* pronti per la validazione finale del KDD.

Parte III — Il modello CRISP-DM

7. Origine e attualità

Il **CRISP-DM (1996)** — *CRoss-Industry Standard Process for Data Mining* — è nato per **standardizzare il data mining**, ma si è evoluto in un **framework fondamentale per la data science, il machine learning e l'analisi avanzata dei dati**. Le sue **sei fasi cicliche** offrono una struttura robusta adattabile a qualsiasi progetto orientato all'analisi dei dati.

La data science moderna **integra il CRISP-DM originale** — pensato per l'informatica degli anni '90 — con soluzioni e tecnologie contemporanee:

- **cloud computing**: piattaforme come **AWS, Azure o GCP** per gestire big data e *training* distribuiti, impossibili con l'hardware dell'epoca;
- **machine learning**: automatizza **implementazione, monitoraggio e riaddestramento** dei modelli, rendendo i progetti pronti per la produzione (è ciò che oggi si chiama **MLOps**);
- **metodologie agili**: sostituiscono il ciclo rigido con **sprint iterativi e feedback continui**, tipici dell'approccio **DevOps**.

8. Il flusso e la decisione chiave

Il diagramma ufficiale mostra un flusso con **frecce bidirezionali fra tutte le fasi consecutive**, che riflettono l'**iteratività non lineare** del processo:

1. si parte dalla **Comprensione del Business** per definire obiettivi e requisiti;
2. si passa alla **Comprensione dei Dati** per esplorare il dataset iniziale;
3. poi alla **Preparazione dei Dati** per pulire e trasformare i dati grezzi;
4. si procede con la **Modellazione** per sviluppare gli algoritmi;
5. e con la **Valutazione** per confrontare i risultati **contro i KPI aziendali**.

In questa fase va presa una **decisione chiave**: se il modello raggiunge gli obiettivi prefissati si procede con l'**Implementazione**; in caso contrario **si torna principalmente alla Comprensione del Business**, per rivedere i requisiti iniziali. Dopo un'implementazione riuscita, **nuovi insight dal modello in produzione riavviano il ciclo** dalla Comprensione del Business.

La freccia che sorprende, e che vale la pena commentare. Quando un modello non funziona, l'istinto è tornare alla *modellazione* — cambiare algoritmo. Il CRISP-DM dice l'opposto: si torna alla **comprensione del business**. Perché il fallimento di un modello, nove volte su dieci, non è un problema tecnico: è il segno che **si è risposto alla domanda sbagliata**. Questa struttura adattiva gestisce incertezze e feedback continui, riducendo i rischi e rendendo il CRISP-DM ideale per progetti scalabili.

9. Le sei fasi in dettaglio

1. Comprensione del Business. Definisce gli **obiettivi strategici**, traducendoli in **problemi di analisi dati specifici e misurabili**. Si identificano le **risorse disponibili** (dati, competenze, budget), i **vincoli legali e organizzativi** e i **criteri di successo** (miglioramenti misurabili nei processi). Risultato concreto: il **piano di progetto**, che **delimita il perimetro** per evitare che il progetto si espanda troppo, con richieste extra che farebbero lievitare costi e tempi (*scope creep*).

2. Comprensione dei Dati. Partendo dagli obiettivi definiti, si raccolgono i **dati iniziali** e si procede con un'**analisi esplorativa (EDA — Exploratory Data Analysis)** per studiarne qualità e caratteristiche. Si identificano problemi comuni — **valori incompleti, outlier, squilibri nelle classi, dati ridondanti** — producendo un **report con le osservazioni chiave** e un **tracciato del flusso dati**.

3. Preparazione dei dati. È la **fase più impegnativa** del CRISP-DM: trasforma dati grezzi e imperfetti in **dataset affidabili e pronti per la modellazione**, attraverso tre macro-attività interconnesse:

- **pulizia:** rimozione dei duplicati, trattamento dei valori mancanti, gestione degli outlier;
- **integrazione:** unione di dati da fonti diverse per creare una **visione completa**, utile ad analisi *cross-dominio* che nessun singolo dataset potrebbe fornire;
- **trasformazione:** **standardizzazione** tramite normalizzazione, **feature engineering**, **selezione degli attributi rilevanti** eliminando ridondanze, **bilanciamento delle classi** e ottimizzazione per gli algoritmi.

4. Modellazione. I dati preparati vengono analizzati con **algoritmi specifici** per identificare pattern nascosti e relazioni significative nei dati storici, producendo un **modello ottimizzato**, completo di **analisi delle variabili principali** e

metriche di performance.

5. Valutazione. Prima della produzione è fondamentale **verificare che il modello raggiunga davvero gli obiettivi aziendali** definiti all'inizio. **Non basta controllare i numeri tecnici**: serve capire se risolve i problemi di business individuati nella prima fase e se **tutte le fasi precedenti sono state eseguite correttamente**, individuando eventuali aspetti trascurati. Se i risultati non convincono, si torna indietro per miglioramenti mirati.

6. Implementazione (deployment). Si integra il modello nei **processi operativi**, con **monitoraggio continuo** per rilevare cambiamenti nei dati e pianificare aggiornamenti. Include **documentazione, formazione del team e gestione del cambiamento organizzativo**.

L'ultima fase è quella che le amministrazioni sottovalutano di più. «Implementazione» non significa consegnare un file: significa **inserire il modello in un processo, formare chi lo userà, e monitorarlo**. I dati cambiano (è il fenomeno del *data drift*), e un modello non monitorato si degrada silenziosamente. Se la commissione ti chiede quale sia il rischio principale di un progetto di data science nella P.A., questa è la risposta migliore: **non che il modello sbaglia, ma che nessuno se ne accorga**.

10. Data science, CRISP-DM e KDD: il confronto finale

La data science **integra sia il KDD sia il CRISP-DM**, estendendo entrambi verso applicazioni che generano **valore concreto** attraverso analisi predittive e automazioni.

	KDD	CRISP-DM
Natura	framework accademico generale per la scoperta della conoscenza nei dati	standard industriale pratico orientato al business
Fasi	5 , con enfasi tecnica sul ciclo di estrazione della conoscenza	6 , strategiche
Punto di forza	granularità tecnica	completezza pratica : gestione manageriale, iteratività strutturata, implementazione produttiva, stakeholder eterogenei

La data science utilizza il **KDD per i fondamenti teorici** e il **CRISP-DM come metodologia operativa preferita** in contesti industriali, **mappando la fase «Data Mining» del KDD sulla fase «Modellazione» del CRISP-DM**.

La risposta completa, in una frase: «KDD e CRISP-DM non sono alternativi: sono lo **stesso processo visto da due punti di vista**. Il KDD lo guarda dal dato — e infatti la sua fase centrale si chiama *data mining*; il CRISP-DM lo guarda dall'organizzazione — e infatti comincia e ricomincia dalla *comprensione del business*. La corrispondenza puntuale è fra il *data mining* del KDD e la *modellazione* del CRISP-DM.»

Da qui in avanti: integrazione. Le Parti IV-X non sono nella scheda. Le ho scritte perché senza di esse la materia del bando resterebbe coperta solo per metà: la scheda spiega **come si organizza** un progetto di analisi

dei dati, ma non **che cosa si fa dentro la scatola**. Sono le parti su cui una commissione approfondisce quando il candidato ha risposto bene sull'impianto metodologico.

Parte IV — I dati: tipi, qualità, dimensioni

11. La tassonomia dei dati

Per struttura:

Tipo	Che cos'è	Esempi nella P.A.
Strutturati	organizzati in righe e colonne, con schema predefinito; risiedono in database relazionali e si interrogano in SQL	anagrafiche, contabilità, tributi, protocollo
Semi-strutturati	hanno una struttura, ma flessibile e auto-descrittiva (XML , JSON)	fatturazione elettronica (XML), API dei servizi digitali
Non strutturati	privi di schema: testo libero, immagini, audio, video	atti amministrativi, PEC, segnalazioni dei cittadini, immagini da telecamere o droni

Si stima che la **grande maggioranza dei dati di un'amministrazione sia non strutturata** — atti, verbali, corrispondenza — ed è esattamente la parte che la contabilità e la statistica tradizionali non toccano. È lì che il *text mining* (§ 28) diventa interessante.

Per scala di misura — è la tassonomia statistica classica, e serve perché **determina quali operazioni sono lecite** e quali algoritmi si possono usare:

Scala	Proprietà	Esempio	Statistica di sintesi
Nominale	solo classificazione	comune di residenza, tipo di atto	moda
Ordinale	classificazione + ordine	livello di istruzione, giudizio di soddisfazione	mediana , quantili
A intervalli	+ distanze costanti, zero convenzionale	temperatura in °C, anno di calendario	media , deviazione standard
A rapporti	+ zero assoluto	reddito, spesa, popolazione, tempi di attesa	tutte, incluse le medie geometriche e i rapporti

L'errore che un funzionario non deve fare. Calcolare la **media di una variabile ordinale** (la «media» dei giudizi da 1 a 5 in un questionario di *customer satisfaction*) è tecnicamente improprio: fra «poco soddisfatto» e «abbastanza soddisfatto» non c'è la stessa distanza che fra «abbastanza» e «molto». Si fa continuamente, anche nelle relazioni ufficiali, e va almeno saputo.

12. La qualità dei dati: le sei dimensioni

La qualità non è un concetto unico. Le dimensioni comunemente riconosciute — e che ritrovi anche nelle linee guida AgID sui dati della P.A. — sono:

Dimensione	Domanda a cui risponde
Accuratezza	il dato corrisponde alla realtà?
Completezza	mancano valori o record?
Consistenza	il dato è coerente fra le diverse fonti che lo contengono?
Tempestività	il dato è aggiornato al momento in cui serve?
Unicità	esistono duplicati dello stesso soggetto o evento?
Validità	il dato rispetta il formato e il dominio ammesso (un codice fiscale ben formato, una data esistente)?

Il principio da citare: *garbage in, garbage out*. Nessun algoritmo, per quanto sofisticato, corregge un dato sbagliato in partenza. E nella P.A. il problema tipico non è l'accuratezza del singolo dato, ma la **consistenza fra banche dati diverse**: lo stesso cittadino con indirizzi diversi in anagrafe, nei tributi e nei servizi sociali. È esattamente il problema che l'**interoperabilità** (§ 26) cerca di risolvere.

13. I big data e le cinque V

Il termine **big data** non indica semplicemente «molti dati»: indica dati che, per una o più delle loro caratteristiche, **non sono trattabili con gli strumenti tradizionali**. Le dimensioni classiche sono tre, poi diventate cinque:

V	Significato
Volume	la quantità: ordini di grandezza che eccedono la capacità di un singolo server
Velocità	la rapidità di generazione e la necessità di elaborazione in tempo reale (<i>streaming</i>)
Varietà	l'eterogeneità dei formati: strutturati, semi-strutturati, non strutturati
Veridicità	l'incertezza sulla qualità e l'affidabilità della fonte
Valore	la capacità effettiva di generare un beneficio: senza di essa, gli altri quattro sono solo un costo

La V che conta nella P.A. è la quinta. Un'amministrazione non ha un problema di volume: ha un problema di **valore**, cioè di trasformare dati che già possiede in decisioni migliori. Dirlo previene l'idea, molto diffusa e molto costosa, che la soluzione sia comprare una piattaforma.

Parte V — Il pre-processing in dettaglio

La scheda elenca le operazioni; qui c'è **come si fanno e perché**, perché è la parte su cui una commissione tecnica approfondisce volentieri.

14. I valori mancanti

Prima di scegliere la tecnica, bisogna capire **perché** il dato manca — la classificazione di Rubin:

- **MCAR** (*missing completely at random*): la mancanza è indipendente da tutto. Rara, ma innocua: eliminare i record non introduce distorsione;
- **MAR** (*missing at random*): la mancanza dipende da **variabili osservate** (il reddito manca più spesso fra i giovani). È il caso più comune: l'imputazione condizionata funziona;
- **MNAR** (*missing not at random*): la mancanza dipende dal **valore stesso non osservato** (chi ha redditi molto alti non li dichiara). È il caso pericoloso: **nessuna imputazione risolve**, e la mancanza va modellata esplicitamente.

Le strategie, in ordine crescente di sofisticazione: **eliminazione** del record o della variabile; **imputazione con media/mediana/moda** (semplice, ma comprime la varianza); **imputazione con k-NN** (preserva le relazioni, come nota la scheda); **imputazione multipla**, che genera più dataset completi e combina i risultati, tenendo conto dell'incertezza dell'imputazione stessa.

15. Gli outlier

Un **outlier** è un'osservazione molto distante dalle altre. Tre metodi di individuazione che vale la pena saper nominare:

- **regola dello scarto interquartile (IQR)**: sono outlier i valori esterni all'intervallo $[Q1 - 1,5 \cdot IQR ; Q3 + 1,5 \cdot IQR]$. È la regola che disegna i «baffi» del **box plot**;
- **regola dello Z-score**: sono sospetti i valori che distano dalla media più di **3 deviazioni standard**;
- **metodi multivariati** (distanza di Mahalanobis, *isolation forest*, *local outlier factor*), necessari quando l'anomalia non è in una singola variabile ma nella **combinazione** di più variabili.

Il punto di metodo, che è anche un punto di sostanza amministrativa: un outlier **non va rimosso per riflesso**. Può essere un errore di misura — e allora si elimina o si corregge — oppure può essere **esattamente il fenomeno che stiamo cercando**: nella lotta all'evasione, nel controllo delle frodi, nella verifica degli appalti anomali, **l'outlier è il risultato, non il disturbo**. La scheda parla di rimozione perché descrive il caso generale; in un contesto di controllo la logica si rovescia.

16. La normalizzazione

Serve perché molti algoritmi **basati sulle distanze** (k-NN, K-Means, SVM, reti neurali) sono sensibili alla scala: una variabile espressa in euro dominerebbe una variabile espressa in anni semplicemente perché ha numeri più grandi.

- **Min-Max**: riporta i valori nell'intervallo $[0,1]$. Conserva la forma della distribuzione ma è **sensibile agli outlier**;

- **Z-score (standardizzazione)**: porta la variabile a media 0 e deviazione standard 1. È **più robusta** ed è la scelta di default;
- **scalatura robusta**: usa mediana e IQR invece di media e deviazione standard, quindi resiste agli outlier.

Non tutti gli algoritmi la richiedono. Gli **alberi decisionali** e gli algoritmi da essi derivati (random forest, gradient boosting) sono **invarianti a trasformazioni monotone**: normalizzare non serve. Saperlo distingue chi ha capito da chi applica ricette.

17. Le variabili categoriali

Gli algoritmi lavorano con numeri: le categorie vanno codificate.

- **one-hot encoding**: crea una variabile binaria per ciascuna categoria. Corretto ma **esplode la dimensionalità** se le categorie sono molte (si pensi agli 8.000 comuni italiani);
- **label encoding**: assegna un intero a ciascuna categoria. Compatto, ma **introduce un ordine inesistente** — è lecito solo per variabili ordinali o per algoritmi ad albero;
- **target encoding**: sostituisce la categoria con la media della variabile risposta in quella categoria. Efficace ma a forte rischio di *leakage*: va calcolato **solo sul training set**.

18. La riduzione dimensionale e la «maledizione della dimensionalità»

All'aumentare del numero di variabili, lo spazio si «svuota»: i punti diventano tutti **equidistanti fra loro**, le distanze perdono significato e i modelli richiedono quantità di dati che crescono esponenzialmente. È la **curse of dimensionality**.

Due famiglie di rimedi:

- **selezione delle variabili (feature selection)**: si scelgono le variabili più informative e si scartano le altre. Metodi *filter* (basati su correlazione o test statistici), *wrapper* (che provano sottoinsiemi valutando il modello), *embedded* (in cui la selezione è interna all'algoritmo, come nella regressione **LASSO**);
- **estrazione di variabili (feature extraction)**: si costruiscono **nuove variabili** combinazione delle originali. La tecnica canonica è la **PCA (analisi delle componenti principali)**, che individua le direzioni di massima varianza e proietta i dati su un numero ridotto di **componenti** fra loro ortogonali.

Il prezzo della PCA, che va sempre dichiarato. Le componenti principali sono **combinazioni lineari** delle variabili originali: si guadagna in compattezza e si **perde in interpretabilità**. In un contesto amministrativo, dove la decisione va motivata, questo prezzo può essere inaccettabile — ed è la ragione per cui, nella P.A., spesso si preferisce la *selezione* all'*estrazione*.

19. Il bilanciamento delle classi

Molti problemi reali sono **fortemente sbilanciati**: le frodi sono l'1% delle pratiche, gli eventi avversi una minoranza dei casi. Un modello che predicesse sempre «nessuna frode» avrebbe **99% di accuratezza ed è inutile**: è il cosiddetto **paradosso dell'accuratezza**.

Rimedi: **oversampling** della classe minoritaria (nella variante **SMOTE**, che genera esempi sintetici invece di duplicare); **undersampling** della classe maggioritaria; **pesi di classe** nell'algoritmo; e soprattutto **cambiare metrica** — usare **precisione, richiamo e F1** invece dell'accuratezza (§ 24).

Parte VI — Il machine learning: la mappa

20. Le tre famiglie

Famiglia	Che cosa riceve	Che cosa impara	Compiti tipici
Apprendimento supervisionato	dati etichettati (coppie input-output)	una funzione che mappa input in output	classificazione, regressione
Apprendimento non supervisionato	dati non etichettati	una struttura latente nei dati	clustering, riduzione dimensionale, regole associative, anomaly detection
Apprendimento per rinforzo	un ambiente e un segnale di ricompensa	una politica di azione che massimizza la ricompensa cumulata	controllo, ottimizzazione sequenziale, gestione dinamica di risorse

Esiste anche il **semi-supervisionato** (poche etichette, molti dati non etichettati), rilevante nella P.A. perché **etichettare costa**: classificare a mano diecimila atti richiede persone e tempo.

21. Il compromesso distorsione-varianza

È il concetto teorico più importante di tutto il machine learning, e si spiega in tre righe:

- un modello **troppo semplice** non coglie la struttura reale: ha **distorsione (*bias*) alta*** — è il **underfitting*****. Sbaglia sia sui dati di addestramento sia su quelli nuovi;
- un modello **troppo complesso** impara anche il **rumore** dei dati di addestramento: ha **varianza alta** — è l'**overfitting**. È quasi perfetto sui dati visti e **crolla su quelli nuovi**;
- l'errore atteso si scompone in **distorsione² + varianza + errore irriducibile**, e il modello migliore è quello che **minimizza la somma**, non uno dei due addendi.

Il sintomo da riconoscere: performance **ottime in addestramento e scarse in test** = overfitting. Performance **scarse in entrambi** = underfitting. È una domanda d'orale frequentissima ed è a risposta secca.

I rimedi all'overfitting: più dati; **regolarizzazione** (penalizzare la complessità: *ridge*, *lasso*); **potatura** degli alberi; **early stopping**; **dropout** nelle reti neurali; e i **metodi ensemble**.

22. La validazione: come si misura davvero un modello

- **holdout**: la divisione train/test descritta dalla scheda ($\approx 80/20$). Semplice, ma il risultato dipende da **quale** divisione è capitata;
- **k-fold cross validation**: si divide il dataset in **k parti**; a turno ciascuna fa da test e le altre $k-1$ da addestramento; si media il risultato sui k giri. Con **k = 5 o 10** è lo standard. È esattamente la «validazione incrociata» del quarto passo del data mining;
- **stratified k-fold**: come sopra, ma **preservando le proporzioni delle classi** in ogni *fold* — obbligatoria con classi sbilanciate;
- **leave-one-out**: caso estremo con $k = \text{numero di osservazioni}$. Usata quando i dati sono pochissimi;
- **nested cross validation**: due cicli annidati, uno per l'ottimizzazione degli iperparametri e uno per la stima delle prestazioni. È l'unico modo **corretto** di fare *tuning* e valutazione insieme, perché evita che il test set «contamini» la scelta dei parametri.

La regola d'oro, e vale la pena enunciarla così: il test set si guarda una volta sola, alla fine. Ogni volta che si usa il test set per decidere qualcosa — quale algoritmo, quali parametri — quel test set **smette di essere una stima onesta** delle prestazioni future. Per decidere serve un terzo insieme, il **validation set**, o la validazione incrociata interna.

Parte VII — Gli algoritmi fondamentali

Qui, come concordato, **nessuna derivazione**: che cosa fa l'algoritmo, quando si usa, qual è il suo punto debole. È il livello a cui una commissione non tecnica si aspetta che tu sappia parlarne.

23. Supervisionati

23.1 Regressione lineare

Stima una variabile numerica come **combinazione lineare** dei predittori. È il modello più semplice, il più interpretabile (ogni coefficiente è l'effetto marginale di una variabile) e il punto di partenza di qualunque analisi. Limite: assume **linearità** e soffre la **multicollinearità** fra predittori.

23.2 Regressione logistica

Nonostante il nome, è un modello di **classificazione**: stima la **probabilità** che un'osservazione appartenga a una classe, vincolandola fra 0 e 1. È lo standard quando serve una **probabilità interpretabile** e una **motivazione** della decisione — e quindi è spesso la scelta giusta nella P.A. anche quando esistono modelli più accurati.

23.3 k-Nearest Neighbors (k-NN)

Classifica un'osservazione guardando le **k osservazioni più vicine** e assegnando la classe prevalente. Non «addestra» nulla: memorizza i dati (*lazy learning*). Semplice e sorprendentemente efficace; richiede **normalizzazione obbligatoria** ed è lento su grandi dataset.

23.4 Alberi decisionali

Costruiscono una sequenza di **domande binarie** sulle variabili, fino ad arrivare a una previsione. La scelta di ogni divisione massimizza la «purezza» dei rami (misurata con **indice di Gini** o **entropia**). Il grande pregio è la **piena interpretabilità**: l'albero si legge come un regolamento. Il difetto è l'**instabilità** — piccole variazioni nei dati producono alberi molto diversi — e la tendenza all'overfitting, che si contrasta con la **potatura**.

23.5 I metodi ensemble

Sono i «metodi ensemble» citati dalla scheda al terzo passo del data mining, e sono oggi lo stato dell'arte sui dati tabellari:

- **bagging** e **Random Forest**: si addestrano molti alberi su campioni diversi (con reinserimento) e su sottoinsiemi casuali di variabili, poi si **media** il risultato. Riduce drasticamente la **varianza**;
- **boosting** (AdaBoost, **Gradient Boosting**, XGBoost, LightGBM): gli alberi si costruiscono **in sequenza**, ciascuno correggendo gli errori del precedente. Riduce la **distorsione** e dà tipicamente le prestazioni migliori, al prezzo di una maggiore sensibilità al rumore e di una minore interpretabilità.

23.6 Support Vector Machine e Naive Bayes

La **SVM** cerca l'iperpiano che separa le classi con il **margin** più ampio, e grazie al *kernel trick* gestisce anche confini non lineari: potente su dataset piccoli e ad alta dimensionalità, poco scalabile. Il **Naive Bayes** applica il teorema di Bayes assumendo l'indipendenza fra le variabili: un'assunzione quasi sempre falsa, eppure l'algoritmo funziona molto bene sulla **classificazione di testi** (è il classico filtro anti-spam), è velocissimo e richiede pochi dati.

23.7 Reti neurali e deep learning

Strati di unità elementari che compongono trasformazioni non lineari. Con molti strati si parla di **deep learning**: è la tecnologia che domina su **immagini, audio, testo e serie complesse**, cioè sui dati **non strutturati**. Richiede **molti dati e molta potenza di calcolo**, ed è il caso tipico di modello **black box**. Sui **dati tabellari**, che sono la stragrande maggioranza dei dati amministrativi, **i metodi ensemble restano competitivi o superiori**: è un'osservazione che vale la pena fare, perché smonta l'idea che il deep learning sia sempre la scelta migliore.

24. Non supervisionati

24.1 K-Means

L'algoritmo di clustering citato dalla scheda. Si fissa a priori il numero **k** di gruppi; l'algoritmo assegna ciascun punto al **centroide più vicino** e ricalcola i centroidi, iterando fino alla stabilità. Veloce e diffusissimo; i limiti: **k va scelto a**

priori (con il **metodo del gomito** o il **coefficiente di silhouette**), tende a produrre **cluster sferici e di dimensioni simili**, ed è **sensibile all'inizializzazione** e agli outlier.

24.2 Clustering gerarchico e DBSCAN

Il **clustering gerarchico** costruisce un **dendrogramma** — un albero di aggregazioni successive — e **non richiede di fissare k in anticipo**: lo si sceglie «tagliando» l'albero all'altezza desiderata. **DBSCAN** individua i cluster come **regioni dense** separate da regioni rade: trova cluster di **forma arbitraria** e classifica automaticamente i punti isolati come **rumore**, il che lo rende naturalmente adatto anche all'*anomaly detection*.

24.3 Regole associative

Cercano co-occorrenze del tipo «chi fa A tende a fare anche B». L'algoritmo classico è **Apriori**. Si valutano con tre indicatori: il **supporto** (quanto è frequente la combinazione), la **confidenza** (con che probabilità B segue A) e il **lift** (quanto la regola è migliore del caso). È la tecnica nata per il *market basket analysis* e trasferibile all'analisi di **percorsi dei cittadini fra i servizi** o di **combinazioni ricorrenti di irregolarità**.

25. Le metriche di valutazione

25.1 Classificazione: la matrice di confusione

Tutto parte da una tabella 2×2 che incrocia **classe reale** e **classe predetta**:

	Predetto positivo	Predetto negativo
Reale positivo	VP (veri positivi)	FN (falsi negativi)
Reale negativo	FP (falsi positivi)	VN (veri negativi)

Da essa discendono le metriche:

Metrica	Che cosa misura	Quando è quella giusta
Accuratezza	quota di previsioni corrette sul totale	solo con classi bilanciate
Precisione	fra i casi segnalati come positivi, quanti lo erano davvero	quando un falso allarme costa (un controllo fiscale a un contribuente in regola)
Richiamo (<i>recall</i> , sensibilità)	fra i casi realmente positivi, quanti ne abbiamo trovati	quando mancare un caso costa (una frode non rilevata, una patologia non diagnosticata)
F1-score	media armonica di precisione e richiamo	con classi sbilanciate , quando servono entrambe — ed è esattamente ciò che dice la scheda
ROC-AUC	capacità di separare le classi a ogni soglia	per confrontare modelli indipendentemente dalla soglia scelta

Precisione e richiamo sono in trade-off, e la scelta **non è tecnica: è politica**. Abbassare la soglia aumenta il richiamo (trovo più casi) e abbassa la precisione (do più falsi allarmi). Decidere dove mettersi lungo questa

curva significa decidere **quale errore l'amministrazione preferisce commettere** — e questa è una decisione che non può essere delegata al data scientist. Se porti questa riflessione all'orale, hai detto la cosa più importante dell'intera materia.

25.2 Regressione e clustering

Per la **regressione**: **MAE** (errore assoluto medio, nell'unità di misura della variabile, robusto agli outlier); **MSE/RMSE** (errore quadratico, penalizza fortemente gli errori grandi); **R²**, la quota di varianza spiegata dal modello.

Per il **clustering**, dove non esiste una «risposta giusta»: il **coefficiente di silhouette** (citato dalla scheda) confronta, per ogni punto, la distanza media dai punti del proprio cluster con quella dai punti del cluster più vicino; varia fra **-1 e +1**, e valori prossimi a 1 indicano gruppi ben separati. Si usano anche l'**indice di Davies-Bouldin** e il **metodo del gomito** sulla varianza interna.

Parte VIII — Dati e algoritmi nella pubblica amministrazione italiana

Questa è la parte decisiva per il tuo concorso. Un candidato che sa spiegare il K-Means fa la figura di uno che ha studiato; un candidato che sa spiegare **che cosa cambia quando l'algoritmo entra in un procedimento amministrativo** fa la figura di un funzionario. La commissione del RIPAM valuta la seconda cosa.

26. Il dato come infrastruttura: il CAD e l'interoperabilità

Il **Codice dell'amministrazione digitale (D.Lgs. 82/2005)** contiene i capisaldi:

- **art. 50 — disponibilità dei dati**: i dati delle pubbliche amministrazioni sono **formati, raccolti, conservati, resi disponibili e accessibili** con l'uso delle tecnologie dell'informazione, e **qualunque dato trattato da una P.A. è reso accessibile e fruibile alle altre amministrazioni** quando l'utilizzazione sia necessaria per lo svolgimento dei loro compiti;
- **art. 50-ter — Piattaforma Digitale Nazionale Dati (PDND)**: l'infrastruttura tecnologica che rende possibile l'**interoperabilità dei sistemi informativi** e delle basi di dati delle amministrazioni, mediante l'**accreditamento, l'identificazione e la gestione dei livelli di autorizzazione** dei soggetti abilitati ad operarvi, e la **raccolta e conservazione delle informazioni relative agli accessi e alle transazioni**;
- **art. 60 — basi di dati di interesse nazionale**: gli insiemi di informazioni omogenee, rilevanti per lo svolgimento delle funzioni istituzionali, la cui disponibilità è essenziale (si pensi all'**ANPR**, l'Anagrafe nazionale della popolazione residente);
- **art. 68, comma 3 — la definizione di dato aperto**: è aperto il dato **disponibile secondo i termini di una licenza che ne permetta l'utilizzo da parte di chiunque, anche per finalità commerciali**, in formato **disaggregato**; accessibile **attraverso le tecnologie dell'informazione e della comunicazione**, in formati **aperti**,

adatti all'utilizzo automatico da parte di programmi e **provvisto dei relativi metadati**; reso disponibile **gratuitamente** o ai soli costi marginali sostenuti per la riproduzione e divulgazione.

Il principio *once only*. Il cittadino non deve fornire più volte alla P.A. un dato che la P.A. già possiede: l'amministrazione lo recupera dalla banca dati che lo detiene. È il senso pratico dell'interoperabilità, ed è il motivo per cui la PDND non è una questione informatica ma **una riforma amministrativa**.

27. Il riutilizzo e gli open data

Il riutilizzo dell'informazione del settore pubblico è disciplinato dal **D.Lgs. 36/2006**, profondamente modificato dal **D.Lgs. 200/2021**, che ha recepito la **Direttiva (UE) 2019/1024 («Open Data»)**. I punti da conoscere:

- il principio è **open data by default**: i documenti detenuti dalle amministrazioni sono **riutilizzabili** a fini commerciali o non commerciali, salvo eccezioni;
- sono individuate categorie di **dati di elevato valore (*high-value datasets*)**, da rendere disponibili **gratuitamente, in formato leggibile meccanicamente e tramite API**: geospaziali, osservazione della terra e ambiente, meteorologici, statistici, sulle imprese, sulla mobilità (l'elenco specifico è nel **Regolamento di esecuzione (UE) 2023/138**);
- si affiancano il **Data Governance Act — Reg. (UE) 2022/868**, che disciplina il riutilizzo di **dati protetti** detenuti dal settore pubblico, gli **intermediari di dati** e l'**altruismo dei dati**, e il **Data Act — Reg. (UE) 2023/2854** sull'accesso ai dati generati da prodotti connessi.

Da non confondere — e la commissione lo chiede. **Trasparenza** (D.Lgs. 33/2013) e **open data** (D.Lgs. 36/2006) hanno finalità diverse: la prima serve al **controllo diffuso** sull'operato dell'amministrazione ed è un obbligo di pubblicazione; il secondo serve alla **creazione di valore** — economico, sociale, conoscitivo — da parte di chiunque, e riguarda il **formato e la licenza**. Un dato può essere pubblicato per trasparenza in un PDF scansionato: è trasparente, **non è un open data**.

28. Il text mining sugli atti amministrativi

Poiché la maggior parte del patrimonio informativo di un'amministrazione è **testo**, vale la pena conoscere il vocabolario minimo del *text mining*, anche solo per governare un affidamento esterno:

- la **pipeline** classica: *tokenizzazione* (spezzare il testo in unità), rimozione delle **stopword**, **stemming** o **lemmatizzazione** (ricondere le parole alla radice o al lemma);
- la **rappresentazione**: **bag of words**, **TF-IDF** (che pesa una parola tanto più quanto è frequente nel documento e rara nel corpus), **word embedding** e oggi i **modelli linguistici di grandi dimensioni**;
- i **compiti tipici applicabili alla P.A.**: **classificazione automatica** di istanze e segnalazioni verso l'ufficio competente; **topic modeling** per capire di che cosa parlano migliaia di segnalazioni; **estrazione di entità** (nomi, date, importi, riferimenti normativi) dagli atti; **ricerca semantica** negli archivi documentali; **sentiment analysis** sulle comunicazioni dei cittadini.

29. Gli usi concreti nel settore pubblico

Vale la pena avere pronti **tre o quattro esempi**, perché la domanda «a che cosa serve, in concreto, in un'amministrazione?» arriva quasi sempre.

Ambito	Tecnica	Uso
Contrasto all'evasione e alle frodi	anomaly detection, classificazione, regole associative	selezione delle posizioni da controllare sulla base del rischio stimato , invece che a campione
Sanità	modelli predittivi, clustering	previsione della domanda di prestazioni, stratificazione della popolazione per rischio, gestione delle liste d'attesa
Manutenzione delle infrastrutture	manutenzione predittiva su dati sensoristici	intervenire prima del guasto su ponti, reti idriche, edifici pubblici
Gestione del personale e dei procedimenti	<i>process mining</i> , analisi dei tempi	individuare i colli di bottiglia nei procedimenti e i motivi reali degli scostamenti dai termini
Politiche pubbliche	metodi controfattuali, matching	valutazione d'impatto degli interventi — il ponte diretto con l'altra materia del tuo bando
Servizi al cittadino	classificazione testi, NLP	instradamento automatico di istanze e segnalazioni, <i>chatbot</i> di primo livello

30. I limiti giuridici: algoritmo e provvedimento amministrativo

È il cuore giuridico della materia, ed è la parte in cui puoi far convergere data science e diritto amministrativo.

30.1 I tre principi del Consiglio di Stato

Con le sentenze della **sez. VI, n. 2270 dell'8 aprile 2019** e **n. 8472 del 13 dicembre 2019** (la vicenda degli algoritmi per la mobilità del personale scolastico), il Consiglio di Stato ha ammesso l'uso dell'algoritmo nel procedimento amministrativo — riconoscendone anzi i vantaggi in termini di **efficienza, imparzialità e velocità** — ma lo ha subordinato a **tre principi**:

Principio	Contenuto
Conoscibilità (e comprensibilità)	l'interessato ha diritto di conoscere l' esistenza di un processo decisionale automatizzato e la logica utilizzata; l'algoritmo, in quanto atto amministrativo informatico, deve essere conoscibile in tutti i suoi aspetti ed è pienamente sindacabile dal giudice
Non esclusività	la decisione non può essere interamente rimessa alla macchina: deve esistere un contributo umano capace di controllare, validare o smentire l'esito automatico (<i>human in the loop</i>)
Non discriminazione algoritmica	il titolare deve utilizzare procedure matematiche o statistiche appropriate , mettere in atto misure per rettificare i fattori che comportano inesattezze e minimizzare il rischio di errori , evitando effetti discriminatori

La formula del Consiglio di Stato che conviene citare quasi alla lettera: l'algoritmo, quando è utilizzato nel procedimento, **non è uno strumento meramente tecnico ma diventa la regola del procedimento stesso**, e come tale deve rispettare tutti i principi che governano l'azione amministrativa — **motivazione, trasparenza, partecipazione, sindacabilità**. Il segreto industriale del fornitore **non può prevalere** sul diritto di difesa dell'interessato.

30.2 Il quadro europeo

- **GDPR, art. 22:** l'interessato ha il **diritto di non essere sottoposto a una decisione basata unicamente sul trattamento automatizzato** — compresa la profilazione — che produca effetti giuridici o incida in modo analogamente significativo sulla sua persona, salvo eccezioni (necessità contrattuale, autorizzazione normativa, consenso esplicito) e comunque con **garanzie minime**: diritto di **ottenere l'intervento umano**, di **esprimere la propria opinione** e di **contestare la decisione**. Vi si affiancano i principi dell'**art. 5 (minimizzazione, limitazione della finalità, esattezza)**, la **privacy by design and by default** dell'**art. 25** e la **valutazione d'impatto sulla protezione dei dati (DPIA)** dell'**art. 35**, obbligatoria proprio nei casi di valutazione sistematica e automatizzata su larga scala;
- **AI Act — Reg. (UE) 2024/1689:** impianto **basato sul rischio**, con quattro livelli — **rischio inaccettabile** (pratiche vietate: *social scoring*, manipolazione, in larga parte l'identificazione biometrica remota in tempo reale in spazi accessibili al pubblico), **alto rischio** (obblighi stringenti di gestione del rischio, qualità dei dati, documentazione, tracciabilità, **sorveglianza umana**, accuratezza e cybersicurezza), **rischio limitato** (obblighi di **trasparenza**: dire all'utente che sta interagendo con un sistema di IA) e **rischio minimo**. **Molti usi tipici del settore pubblico ricadono nell'alto rischio** — accesso a servizi essenziali, valutazione dell'affidabilità creditizia, occupazione e selezione del personale, istruzione, giustizia, migrazione;
- in Italia, la **L. 23 settembre 2025, n. 132** ha dettato disposizioni in materia di intelligenza artificiale e deleghe al Governo, muovendosi nel solco dell'AI Act e ribadendo, per il settore pubblico, il principio della **centralità della decisione umana** e della **tracciabilità** dei sistemi utilizzati. (*È normativa recentissima: verifica lo stato dei decreti attuativi prima dell'orale.*)

30.3 Il bias algoritmico: da dove viene davvero

Un punto che vale la pena chiarire perché è quasi sempre frainteso: **l'algoritmo non è «prevenuto»; lo sono i dati**. Le fonti principali:

- **bias storico:** i dati riflettono **discriminazioni già avvenute**. Un modello addestrato sui controlli fiscali del passato imparerà a controllare le stesse categorie di prima, a prescindere dal rischio reale;
- **bias di campionamento:** alcuni gruppi sono **sotto-rappresentati** nei dati, e il modello funziona peggio su di loro;
- **bias di misura:** la variabile osservata è un **proxy imperfetto** di ciò che interessa davvero (si usa «numero di controlli con esito positivo» come proxy di «evasione», ma si misurano i controlli, non l'evasione);
- **feedback loop:** il modello indirizza i controlli su un gruppo, i controlli generano nuovi dati su quel gruppo, i nuovi dati confermano il modello. **La profezia si autoavvera.**

La conclusione da portare all'orale: la correttezza di un sistema algoritmico **non è una proprietà del codice, è una proprietà del processo**. Si garantisce con la **qualità e la rappresentatività dei dati**, con la **valutazione d'impatto preventiva**, con il **monitoraggio delle prestazioni disaggregate per gruppo** e con la **sorveglianza umana effettiva** — non formale. È esattamente l'architettura che l'AI Act impone ai sistemi ad alto rischio, e coincide con i tre principi del Consiglio di Stato.

31. Il sistema statistico nazionale

Chiude il quadro istituzionale, ed è il collegamento con la **statistica economica per le PA**, altra materia del bando: il **SISTAN** — Sistema statistico nazionale, istituito dal **D.Lgs. 322/1989** — è la rete che collega **ISTAT**, uffici di statistica di amministrazioni centrali e locali, enti e organismi pubblici di informazione statistica. Produce la **statistica ufficiale** secondo il **Programma statistico nazionale**, nel rispetto dei principi del **Codice italiano delle statistiche ufficiali** e del **Codice delle statistiche europee: indipendenza professionale, imparzialità, obiettività, affidabilità, segreto statistico**.

La distinzione fondamentale, che vale un punto: il segreto statistico (art. 9, D.Lgs. 322/1989) impone che i dati raccolti a fini statistici **possano essere usati solo per fini statistici** e diffusi **esclusivamente in forma aggregata**, in modo che non se ne possa trarre alcun riferimento individuale. È un vincolo **ulteriore e diverso** rispetto alla protezione dei dati personali: vale anche quando il trattamento sarebbe lecito ai sensi del GDPR. Ed è la ragione per cui un dato può essere legittimamente raccolto per una finalità amministrativa e **non** essere riutilizzabile per un'altra.

Parte IX — Le dieci formule che vale la pena sapere

Come concordato: **niente derivazioni**. Queste dieci si scrivono in pochi secondi e coprono tutto ciò che può essere chiesto a un funzionario. Valuta tu quali memorizzare; le prime quattro sono quelle che consiglierai a chiunque.

1. Accuratezza — quota di previsioni corrette

$$\text{Accuratezza} = (VP + VN) / (VP + VN + FP + FN)$$

2. Precisione — fra i segnalati, quanti erano davvero positivi

$$\text{Precisione} = VP / (VP + FP)$$

3. Richiamo (sensibilità) — fra i positivi reali, quanti ne ho trovati

$$\text{Richiamo} = VP / (VP + FN)$$

4. F1-score — media armonica di precisione e richiamo

$$F1 = 2 \times (\text{Precisione} \times \text{Richiamo}) / (\text{Precisione} + \text{Richiamo})$$

5. Specificità — fra i negativi reali, quanti ne ho riconosciuti

$$\text{Specificità} = VN / (VN + FP)$$

6. Errore quadratico medio e sua radice — per la regressione

$$MSE = \text{media degli (valore osservato - valore previsto)}^2 \cdot RMSE = \sqrt{MSE}$$

7. Coefficiente di determinazione — quota di varianza spiegata

$$R^2 = 1 - (\text{devianza residua} / \text{devianza totale})$$

8. Standardizzazione Z-score

$$z = (x - \text{media}) / \text{deviazione standard}$$

9. Normalizzazione Min-Max

$$x' = (x - \text{minimo}) / (\text{massimo} - \text{minimo})$$

10. Distanza euclidea — il fondamento di k-NN e K-Means

$$d(a, b) = \sqrt{\sum (a_i - b_i)^2}$$

Bonus, se vuoi una carta in più: le tre misure delle **regole associative**. *Supporto* = frequenza della combinazione sul totale; *Confidenza* = $P(B|A)$; *Lift* = $\text{Confidenza} / P(B)$. Un lift maggiore di 1 indica associazione positiva, pari a 1 indipendenza, minore di 1 associazione negativa.

Domande d'orale — 60 domande con la traccia della risposta

Impianto (dalla scheda: qui devi essere impeccabile)

1. **Che cos'è la data science?** — *Disciplina trasversale che integra statistica, programmazione, machine learning e conoscenza di dominio per trasformare dati grezzi in informazioni utili, anche a fini predittivi.*

2. **Chi ha usato per primo il termine e quando?** — Peter Naur, 1974, come evoluzione della «datalogy»; ma l'idea di analisi dei dati come campo autonomo è di John Tukey, anni '60. Cleveland nel 2001 con «Data Science: An Action Plan».
3. **Quando è stato formalizzato il KDD?** — Nel 1996 da Fayyad, sulle basi poste negli anni '80 dai database relazionali.
4. **Che rapporto c'è fra data science, KDD e data mining?** — La data science è il campo ampio che copre l'intero ciclo di vita del dato; il KDD è il processo tecnico di estrazione della conoscenza; il data mining è la fase centrale del KDD. Aggancio: il data mining occupa circa il 20% del tempo totale.
5. **Quali sono le cinque fasi del KDD?** — Selezione; pulizia e integrazione; trasformazione; data mining; valutazione e presentazione dei pattern.
6. **Che cosa si fa nella fase di pulizia?** — Rimozione outlier; riempimento dei mancanti (media/mediana o k-NN); eliminazione duplicati; integrazione da fonti diverse.
7. **Perché imputare con il k-NN e non con la media?** — La media cancella le relazioni complesse fra variabili e comprime la varianza; il k-NN imputa un valore coerente con i record simili.
8. **Quali tecniche di trasformazione?** — Normalizzazione Min-Max o Z-score; feature engineering; discretizzazione; riduzione dimensionale con PCA.
9. **Quali sono le tecniche di data mining?** — Clustering, classificazione, regressione, sintesi, modellazione delle dipendenze, rilevamento anomalie.
10. **Come si valutano i pattern trovati?** — Metriche quantitative (accuratezza, precisione/richiamo, F1 per dataset sbilanciati, silhouette per i cluster), test statistici, e confronto con l'esperto di dominio.
11. **Quali sono i sei passi operativi del data mining?** — Preparazione del dataset; selezione algoritmi; addestramento; validazione incrociata; ottimizzazione parametri; generazione pattern.
12. **Come si divide il dataset?** — Circa 80% training e 20% test; stratified sampling per preservare le proporzioni delle classi, split temporale per dati cronologici.
13. **Perché lo split temporale per i dati cronologici?** — Per evitare di addestrare sul futuro e prevedere il passato: è data leakage, gonfia le prestazioni e crolla in produzione.
14. **Che cos'è il CRISP-DM e quando nasce?** — Standard industriale del 1996 per il data mining, evoluto in framework generale; sei fasi cicliche con frecce bidirezionali.
15. **Elenchi le sei fasi del CRISP-DM.** — Comprensione del business; comprensione dei dati; preparazione dei dati; modellazione; valutazione; implementazione.
16. **Qual è la fase più impegnativa?** — La preparazione dei dati: pulizia, integrazione, trasformazione.
17. **Qual è la decisione chiave del CRISP-DM?** — In valutazione: se il modello raggiunge gli obiettivi si implementa, altrimenti si torna alla comprensione del business, non alla modellazione.
18. **Che cos'è l'EDA?** — Exploratory Data Analysis, l'analisi esplorativa della fase di comprensione dei dati: qualità, valori incompleti, outlier, squilibri, ridondanze.
19. **Come la data science moderna aggiorna il CRISP-DM?** — Cloud computing per big data e training distribuiti; automazione di deployment, monitoraggio e riaddestramento (MLOps); metodologie agili al posto del ciclo rigido.
20. **Differenze fra KDD e CRISP-DM?** — KDD: accademico, 5 fasi, granularità tecnica. CRISP-DM: industriale, 6 fasi, completezza pratica e orientamento al business. Il data mining del KDD corrisponde alla modellazione del CRISP-DM.

Dati e pre-processing

21. **Dati strutturati, semi-strutturati e non strutturati?** — Schema fisso in database relazionali; struttura flessibile e auto-descrittiva (XML, JSON); testo, immagini, audio senza schema.
22. **Quali sono le scale di misura?** — Nominale, ordinale, a intervalli, a rapporti; determinano quali operazioni e quali statistiche di sintesi siano lecite.
23. **Quali sono le dimensioni della qualità del dato?** — Accuratezza, completezza, consistenza, tempestività, unicità, validità.
24. **Che cosa sono i big data?** — Le cinque V: volume, velocità, varietà, veridicità, valore. Aggancio: nella P.A. il problema non è il volume, è il valore.
25. **Perché un dato può mancare?** — MCAR, MAR, MNAR. Solo nel terzo caso l'imputazione non risolve e la mancanza va modellata.
26. **Come si individuano gli outlier?** — Regola dell'IQR (1,5 volte lo scarto interquartile, i baffi del box plot); Z-score oltre 3 deviazioni standard; metodi multivariati.
27. **Un outlier va sempre rimosso?** — No: può essere un errore di misura oppure il fenomeno cercato. Nel controllo delle frodi l'outlier è il risultato, non il disturbo.
28. **Quando serve normalizzare?** — Per algoritmi basati sulle distanze (k-NN, K-Means, SVM, reti neurali). Gli alberi e i metodi ensemble non lo richiedono.
29. **Come si codificano le variabili categoriali?** — One-hot (corretto, ma esplode la dimensionalità); label encoding (compatto, introduce un ordine falso); target encoding (efficace, a rischio di leakage).
30. **Che cos'è la maledizione della dimensionalità?** — All'aumentare delle variabili i punti diventano equidistanti, le distanze perdono significato e servono dati esponenzialmente maggiori.
31. **Selezione o estrazione di variabili?** — La selezione conserva l'interpretabilità; l'estrazione (PCA) comprime meglio ma produce combinazioni lineari non interpretabili. Nella P.A., dove la decisione va motivata, spesso si preferisce la selezione.
32. **Che cos'è il paradosso dell'accuratezza?** — Con classi molto sbilanciate un modello banale ha accuratezza altissima ed è inutile: servono precisione, richiamo e F1, oppure SMOTE e pesi di classe.

Machine learning e algoritmi

33. **Quali sono le famiglie di apprendimento?** — Supervisionato, non supervisionato, per rinforzo; più il semi-supervisionato, rilevante nella P.A. perché etichettare costa.
34. **Classificazione o regressione?** — Entrambe supervisionate: la prima prevede una categoria, la seconda un valore numerico.
35. **Che cos'è il trade-off bias-varianza?** — Modello troppo semplice: distorsione alta, underfitting. Troppo complesso: varianza alta, overfitting. L'errore atteso è $\text{distorsione}^2 + \text{varianza} + \text{errore irriducibile}$.
36. **Come si riconosce l'overfitting?** — Ottime prestazioni in addestramento, scarse in test. Rimedi: più dati, regolarizzazione, potatura, early stopping, dropout, metodi ensemble.
37. **Che cos'è la k-fold cross validation?** — Si divide il dataset in k parti, a turno una fa da test e le altre da addestramento, si media sui k giri. Standard: $k = 5$ o 10 ; stratificata con classi sbilanciate.
38. **Qual è la regola d'oro sul test set?** — Si guarda una volta sola, alla fine. Per decidere serve un validation set o una validazione incrociata interna, altrimenti la stima non è più onesta.

39. **Come funziona il K-Means?** — Si fissa k , si assegna ogni punto al centroide più vicino, si ricalcolano i centroidi, si itera. Limiti: k a priori, cluster sferici, sensibilità a inizializzazione e outlier.
40. **Come si sceglie k ?** — Metodo del gomito sulla varianza interna e coefficiente di silhouette.
41. **Che cos'è il coefficiente di silhouette?** — Confronta per ogni punto la distanza media interna al cluster con quella dal cluster più vicino; varia fra -1 e $+1$, valori alti indicano gruppi ben separati.
42. **Clustering gerarchico e DBSCAN: che vantaggi hanno?** — Il gerarchico non richiede k a priori e produce un dendrogramma; DBSCAN trova cluster di forma arbitraria e isola il rumore, quindi serve anche all'anomaly detection.
43. **Che cos'è un albero decisionale?** — Sequenza di domande binarie che massimizzano la purezza (Gini o entropia). Pregio: piena interpretabilità. Difetti: instabilità e overfitting, mitigati dalla potatura.
44. **Bagging o boosting?** — Il bagging (Random Forest) addestra alberi in parallelo su campioni diversi e media: riduce la varianza. Il boosting li costruisce in sequenza correggendo gli errori: riduce la distorsione, dà prestazioni migliori ma è più sensibile al rumore.
45. **Perché la regressione logistica resta importante?** — Restituisce una probabilità interpretabile e una motivazione della decisione: spesso è la scelta giusta nella P.A. anche quando esistono modelli più accurati.
46. **Quando serve il deep learning?** — Su dati non strutturati — immagini, audio, testo — con molti dati e molta potenza. Sui dati tabellari, che sono la maggioranza dei dati amministrativi, i metodi ensemble restano competitivi.
47. **Che cosa sono le regole associative?** — Co-occorrenze del tipo «chi fa A tende a fare B», estratte con Apriori e valutate con supporto, confidenza e lift.
48. **Precisione o richiamo?** — Dipende da quale errore costa di più: la precisione quando pesa il falso allarme, il richiamo quando pesa il caso mancato. La scelta della soglia non è tecnica, è una decisione di policy.
49. **Che cos'è la curva ROC e l'AUC?** — Rappresentano la capacità di separare le classi a ogni soglia; l'area sotto la curva consente di confrontare modelli indipendentemente dalla soglia scelta.
50. **Quali metriche per la regressione?** — MAE (robusto, nell'unità della variabile), MSE/RMSE (penalizza gli errori grandi), R^2 (varianza spiegata).

Dati e algoritmi nella P.A.

51. **Che cos'è la PDND?** — Piattaforma Digitale Nazionale Dati, art. 50-ter CAD: infrastruttura per l'interoperabilità delle basi di dati delle amministrazioni, con accreditamento, livelli di autorizzazione e tracciamento degli accessi. Attua il principio once only.
52. **Che cos'è un dato aperto?** — Art. 68, comma 3, CAD: licenza che ne consenta l'uso da parte di chiunque anche per fini commerciali; formato disaggregato, aperto, leggibile meccanicamente, con metadati; gratuito o ai soli costi marginali.
53. **Trasparenza e open data sono la stessa cosa?** — No: la trasparenza (D.Lgs. 33/2013) serve al controllo diffuso ed è obbligo di pubblicazione; gli open data (D.Lgs. 36/2006, come modificato dal D.Lgs. 200/2021) servono alla creazione di valore e riguardano formato e licenza. Un PDF scansionato è trasparente ma non è open data.
54. **Che cosa sono gli high-value datasets?** — Categorie di dati a elevato valore da rendere disponibili gratuitamente, in formato leggibile meccanicamente e via API (Dir. UE 2019/1024; Reg. di esecuzione UE 2023/138): geospaziali, ambiente, meteo, statistica, imprese, mobilità.

55. **Quali principi ha posto il Consiglio di Stato sull'algoritmo nel procedimento?** — Sentenze sez. VI 2270/2019 e 8472/2019: conoscibilità e comprensibilità, non esclusività (contributo umano), non discriminazione algoritmica. L'algoritmo diventa la regola del procedimento e come tale è sindacabile; il segreto industriale non prevale sul diritto di difesa.
56. **Che cosa prevede l'art. 22 del GDPR?** — Diritto di non essere sottoposti a decisioni basate unicamente sul trattamento automatizzato con effetti giuridici significativi, salvo eccezioni e con garanzie minime: intervento umano, espressione della propria opinione, contestazione della decisione.
57. **Come è strutturato l'AI Act?** — Reg. UE 2024/1689, approccio basato sul rischio: inaccettabile (pratiche vietate), alto (obblighi stringenti, inclusa la sorveglianza umana), limitato (trasparenza), minimo. Molti usi del settore pubblico ricadono nell'alto rischio.
58. **Da dove viene il bias algoritmico?** — Dai dati, non dal codice: bias storico, di campionamento, di misura, e feedback loop. Si contrasta con qualità dei dati, valutazione d'impatto preventiva, monitoraggio disaggregato per gruppo e sorveglianza umana effettiva.
59. **Che cos'è il segreto statistico?** — Art. 9 D.Lgs. 322/1989: i dati raccolti a fini statistici sono utilizzabili solo per fini statistici e diffusi solo in forma aggregata. È un vincolo ulteriore e diverso rispetto al GDPR.
60. **A che cosa serve, in concreto, il data mining in un'amministrazione?** — Selezione dei controlli per rischio nel contrasto a evasione e frodi; previsione della domanda in sanità; manutenzione predittiva delle infrastrutture; process mining sui procedimenti; valutazione controfattuale d'impatto delle politiche; instradamento automatico di istanze e segnalazioni.
-

Come collegare questa materia alle altre del bando

È il vero valore di questa dispensa per il tuo orale: la data science è la materia che **tocca tutte le altre**, e una commissione lo apprezza moltissimo.

- **con la valutazione delle politiche pubbliche** — è il collegamento più forte: gli **indicatori di output e outcome** del D.P.C.M. 18-9-2012 sono lo stesso problema di misurazione che il data mining affronta; e i **metodi controfattuali** (differenze nelle differenze, *matching*, discontinuità nella regressione) sono machine learning applicato alla causalità. La frase da avere pronta: «*un modello predittivo dice che cosa accadrà, un disegno controfattuale dice che cosa sarebbe accaduto senza l'intervento: la valutazione ha bisogno del secondo, e confonderli è l'errore più costoso*»;
- **con l'econometria e la statistica** — regressione, inferenza, test: stessa cassetta degli attrezzi, finalità diverse. **L'econometria cerca il coefficiente** (l'effetto causale, con la sua significatività); **il machine learning cerca la previsione** (e accetta modelli non interpretabili pur di sbagliare meno);
- **con la contabilità pubblica** — i **piani dei conti integrati**, il **SIOPE** e la **BDAP** sono, in senso proprio, **infrastrutture di dati**: codifiche uniformi che rendono i dati confrontabili e consolidabili. È esattamente il problema dell'integrazione da fonti diverse della seconda fase del KDD, risolto per via normativa;
- **con il diritto amministrativo** — **motivazione del provvedimento, accesso agli atti, responsabilità**: i tre principi del Consiglio di Stato sono la traduzione dell'algoritmo nel linguaggio della L. 241/1990;
- **con le tecnologie informatiche** (l'altra prova del tuo orale) — il vocabolario di questa dispensa è già metà del programma: basi di dati e SQL, formati aperti, API, interoperabilità, CAD.

Metodo per gli ultimi giorni

Tre cose da saper fare alla lavagna, perché sono quelle che una commissione chiede di disegnare: il **ciclo CRISP-DM** con le sei fasi e la freccia di ritorno dalla valutazione alla comprensione del business; la **matrice di confusione** 2×2 con le quattro celle; lo **schema delle inclusioni** fra data science, KDD, data mining e machine learning.

Tre numeri da ricordare: 1996 (Fayyad formalizza il KDD; nasce il CRISP-DM), 80/20 (training/test), 20% (quota del data mining sul tempo totale di un progetto di data science).

Una convinzione da trasmettere. In tutta la materia c'è un'unica idea che conta davvero, ed è che **il modello è la parte facile**. La parte difficile — e la parte che riguarda un funzionario pubblico — è **decidere quale domanda porre, procurarsi dati di qualità, capire quale errore l'amministrazione può permettersi di commettere, e garantire che una persona resti responsabile della decisione**. Se questa idea attraversa le tue risposte, l'orale su questa materia è chiuso bene.

Dispensa redatta sulla scheda «Elementi di data science e data mining» (Simone, edizione per il Concorso RIPAM 294 posti), riportata integralmente nelle Parti I-III, e integrata nelle Parti IV-X con il contenuto tecnico e giuridico necessario alla prova orale. Normativa citata aggiornata al quadro vigente; la L. 132/2025 sull'intelligenza artificiale è di adozione recentissima e va verificata quanto ai decreti attuativi.