Moda e mediana

Manuale, cap. 1, §5.7-5.9, pp. 276-279. Con i due esempi numerici svolti dal libro (Esempio 13 e Esempio 14) ricostruiti per intero.

Dove siamo, e perché queste due stanno insieme

A p. 269 il manuale divide gli indici di posizione in due famiglie:

	Come si calcolano	**Quali sono**
medie analitiche	considerando **tutti** i valori della distribuzione	aritmetica, quadratica, armonica, geometrica
medie lasche	considerando **solo alcuni** elementi della distribuzione	**moda**, **mediana**

Moda e mediana sono medie lasche, e questa non è un'etichetta: è la loro natura. Non fanno conti su tutti i dati — **guardano una posizione**. La moda guarda dove i dati si addensano; la mediana guarda chi sta in mezzo alla fila.

> **La conseguenza, che è la cosa più importante di tutto il documento.** Una media analitica usa ogni singolo valore, quindi **un solo dato estremo la sposta**. Una media lasca no: **è robusta**.
>
> È il motivo per cui sui redditi si pubblica la **mediana** e non la media. Entra un miliardario nel collettivo: la media aritmetica di tutti sale, la mediana **non si muove di un centimetro**, perché continua a essere il valore di chi sta a metà della graduatoria.

PARTE PRIMA — LA MODA

La definizione

> **La moda è la modalità che presenta la frequenza più alta.**

Cioè: **il valore che si presenta più spesso**. È l'unico indice di posizione che si può calcolare anche su un **carattere qualitativo** — non esiste la provincia media né la provincia mediana, ma **la provincia più frequente esiste**. Vale la pena dirlo all'orale: mostra che hai capito a che cosa serve.

Il manuale distingue **tre casi**, ed è proprio sul terzo che si viene interrogati.

Caso 1 — Modalità singole

Si scorrono le modalità **una ad una** e si prende quella con la frequenza maggiore. Non c'è altro.

Caso 2 — Dati in classi di uguale ampiezza

La moda cade nella classe avente la frequenza più alta.

Qui frequenza e densità danno lo stesso risultato, e il manuale lo dice espressamente: la classe modale è quella che presenta, **indifferentemente**, la maggiore frequenza **o** la maggiore densità di frequenza. Se le classi sono larghe uguale, le due strade coincidono.

Caso 3 — Dati in classi di diversa ampiezza ← *il caso d'esame*

Qui la frequenza da sola inganna, e bisogna passare alla **densità di frequenza**.

> **La densità di frequenza è il rapporto fra la frequenza di ciascuna classe e l'ampiezza della classe stessa.** Operativamente, il manuale divide la frequenza della classe per **il numero di valori del carattere contenuti in essa**.
>
> **La moda cade nella classe che presenta il quoziente più alto**, cioè la densità di frequenza più alta.

Perché serve, in una frase. Una classe larghissima raccoglie tanti casi **solo perché è larga**, non perché lì i dati si addensino. La densità corregge esattamente questo: misura **quanti casi per unità di ampiezza**, cioè l'affollamento reale.

Ed è per questo che il manuale, parlando di caratteri continui, dà alla moda questa definizione:

> **la moda è quel valore intorno a cui i casi sono addensati in maggior misura.**

L'Esempio 13 del manuale — svolto

Distribuzione delle imprese di un'area per classi di dipendenti.

Classi di dipendenti	Numero di aziende
10 - 30	21
30 - 50	30
50 - 75	35
75 - 100	30
100 - 150	34
150 - 200	13
200 - 350	75
350 - 600	**148**
Totale	**386**

Guarda la colonna delle frequenze. Il massimo è **148**, nella classe «350-600 dipendenti». Se ti fermassi qui, diresti che la classe modale è quella. **È la risposta sbagliata**, e il manuale la mette lì apposta.

Il motivo: quella classe è larga **250 valori**, le prime sono larghe venti. Ovvio che raccolga più casi.

Ora la tabella corretta. Per ogni classe: frequenza, numero di valori del carattere contenuti nella classe, e il loro quoziente.

Classe	Frequenza	N. di valori	Densità
10 - 30	21	21	1,000
31 - 50	**30**	**20**	**1,500** ←
51 - 75	35	25	1,400
76 - 100	30	25	1,200
101 - 150	34	50	0,680
151 - 200	13	50	0,260
201 - 350	75	150	0,500
351 - 600	148	250	0,592
Totale	**386**		

Il quoziente massimo è 1,5, e si rileva per la classe **«31-50 dipendenti»**: quella, e non l'altra, è **la classe modale**.

Guarda che cosa è successo alla classe «351-600»: aveva la frequenza più alta in assoluto (148) e finisce **al quinto posto per densità** (0,592). Centoquarantotto aziende sparse su 250 valori sono **meno affollate** di trenta aziende su venti valori.

> **Da dire all'orale, ed è la risposta completa:** *«Quando le classi hanno ampiezza diversa non si può guardare la frequenza, perché una classe più larga raccoglie più casi solo in virtù della sua ampiezza. Si usa la densità*

> *di frequenza, cioè il rapporto fra la frequenza della classe e la sua ampiezza, e la classe modale è quella con la densità più alta. Il manuale porta un esempio in cui la classe con la frequenza massima non è affatto la classe modale.»*

PARTE SECONDA — LA MEDIANA

La definizione

> Data una variabile statistica le cui intensità siano ordinate **in senso crescente o decrescente**, **la mediana è quell'indice di posizione corrispondente al valore che bipartisce la distribuzione, lasciando metà dei casi a sinistra e metà a destra.**

Due parole da non perdere.

«Ordinate». La mediana **non esiste** se prima non metti i dati in fila. È il primo gesto, ed è quello che la rende un indice *di posizione in graduatoria* e non un calcolo.

«Bipartisce». Non divide in parti uguali di *valore*: divide in due parti uguali **di numerosità**. Metà dei casi di qua, metà di là.

Caso A — Dati non raggruppati in classi

Si cerca **il posto centrale**, e ci sono due situazioni.

Se le osservazioni sono in numero dispari il posto centrale è **uno solo**, e la mediana è l'intensità che occupa quel posto.

Se le osservazioni sono in numero pari i posti centrali sono **due**, e si assume come mediana **la media aritmetica delle due intensità** che li occupano.

> Nota curiosa e utile: nel caso pari, **la mediana può essere un valore che non compare fra i dati**. Se i due centrali sono 40 e 45, la mediana è 42,5, che nessuno ha. Non è un errore: la mediana è una *posizione*, non per forza un'osservazione.

Caso B — Dati raggruppati, carattere discreto

Il manuale dà una procedura in cinque passi. Te la riporto così com'è, e poi te la traduco.

1. **si calcola il posto centrale**, come nel caso dei dati non raggruppati;
2. **sulla base delle frequenze cumulate si determina la classe in cui cade la mediana**;
3. si determina **la differenza fra il posto centrale e la frequenza cumulata fino alla classe che precede** quella contenente la mediana;

4. si divide **la frequenza della classe mediana per l'ampiezza** della stessa classe;
5. si divide **la differenza del punto 3 per il quoziente del punto 4**.

Che cosa stai facendo davvero. Il passo 2 ti dice *in quale classe* cade la mediana. I passi 3-5 ti dicono **quanto avanzare dentro quella classe**: il risultato è la quantità da **aggiungere all'estremo inferiore della classe mediana** — come conferma l'esempio svolto del manuale, che infatti parte da 30 e ci somma il resto.

Caso C — Dati raggruppati, carattere continuo

Si considera **la spezzata cumulativa**, cioè il grafico che rappresenta le frequenze cumulate, e si **interpola** dentro la classe mediana.

Il manuale precisa come si ottiene il risultato: **considerando i triangoli simili** ABD e AB'D' costruiti sulla spezzata. Non devi saperlo dimostrare — devi sapere **che il metodo è una proporzione geometrica**: dentro la classe mediana si assume che i casi siano distribuiti in modo uniforme, e si avanza in proporzione.

Gli elementi che entrano nel calcolo, con i nomi che usa il manuale:

Simbolo	**Che cos'è**
estremo inferiore della classe mediana	da dove si parte
ampiezza della classe mediana	quanto è larga
frequenza della classe mediana	quanti casi contiene
C	il posto centrale
frequenza cumulata fino alla classe **precedente**	quanti casi sono già alle spalle

L'Esempio 14 del manuale — svolto passo per passo

Presenze in un villaggio turistico, per classi di età.

Classi di età	**Frequenza**	**Frequenza cumulata**
0 - 20	94	94
20 - 30	104	198
30 - 50	**132**	**330** ←
50 - 60	121	451
60 - 80	70	521
oltre 80	18	539
Totale	**539**	

Passo 1 — il posto centrale. Le osservazioni sono **539, numero dispari**. Il posto centrale è **270**.

Passo 2 — in quale classe cade. Si scorre la colonna delle **frequenze cumulate**: fino alla seconda classe siamo a 198, quindi il 270° non c'è ancora; alla terza siamo a 330, e il 270° è compreso. **La classe mediana è la terza: «età fra i 30 e i 50 anni».**

> Qui il manuale usa un'immagine che conviene rubare: *il turista che presenta l'età mediana è il 270°*. Non un'età: **una persona in fila**.

Passo 3 — quanto avanzare. Dentro quella classe bisogna andare avanti di **270 − 198 = 72** posti.

Passo 4 — in proporzione. La classe è larga **20 anni** e contiene **132** persone. Avanzare di 72 posti su 132 significa percorrere 72/132 della classe, cioè **20 × (72/132) = 10,91 anni**.

Passo 5 — il risultato. Si parte dall'estremo inferiore della classe, **30**, e si aggiunge:

> **Me = 30 + 10,91 = 40,91 → l'età mediana stimata è 40,91 anni.**

La parola «stimata» non è decorativa. È una stima perché, non conoscendo le età una per una ma solo la classe, **si assume che dentro la classe 30-50 le persone siano distribuite uniformemente**. Dirlo all'orale è il dettaglio che separa chi ha applicato una procedura da chi l'ha capita.

Le due proprietà della mediana

Il manuale ne enuncia due, e **la seconda è quella che vale un voto in più**.

Prima proprietà. Considerando gli scarti dei dati dalla mediana, **il numero degli scarti di segno positivo è uguale al numero degli scarti di segno negativo.** È la definizione stessa, vista dall'altro lato: se metà dei casi sta sotto e metà sopra, gli scarti si bilanciano **come numero**.

Seconda proprietà. La somma dei valori assoluti degli scarti dalla mediana è minima. Il manuale lo precisa: scegliendo un qualsiasi altro numero al posto della mediana, quella somma viene più grande.

> **Che cosa significa, in parole, e perché impressiona.** La mediana è **il punto che minimizza la distanza complessiva da tutti i dati**, se le distanze si misurano in valore assoluto.
>
> Un'immagine da usare all'orale: *dovendo aprire un unico sportello che serva tutti i comuni disposti lungo una strada, il punto che rende minima la somma dei chilometri percorsi da tutti non è il punto medio della strada — è il punto mediano, quello che lascia metà dei comuni da un lato e metà dall'altro.*
>
> **E il collegamento che chiude il discorso**: la media aritmetica gode della proprietà analoga, ma rispetto agli scarti **al quadrato**. Mediana ↔ valori assoluti; media ↔ quadrati. È per questo che la media è sensibile agli estremi e la mediana no: **il quadrato amplifica i valori lontani, il valore assoluto no.**

PARTE TERZA — I PERCENTILI (§5.9)

> **I percentili sono indici di posizione che suddividono la distribuzione in due parti, lasciando da un lato una data percentuale dei casi e dall'altro la restante percentuale.**

La mediana, vista così, è semplicemente **il caso 50/50**.

I numeri esatti — ed è precisamente il tipo di cosa che un commissario pignolo chiede:

	Quanti sono	Che cosa fanno
terzili	**2**	T_1 lascia a sinistra il **33,3%**; T_2 lascia a sinistra il **66,7%**
quartili	**3**	Q_1 → **25%**; **Q_2 → 50%, e coincide con la mediana**; Q_3 → **75%**
decili	**9**	tagliano in dieci parti
centili	**99**	tagliano in cento parti

> **La regola che li tiene insieme:** per dividere una distribuzione in *k* parti servono **k − 1** tagli. Due terzili per tre parti, tre quartili per quattro, nove decili per dieci, novantanove centili per cento. Se ricordi questa riga non sbagli mai il numero.

E la cosa da dire sempre: Q_2 è la mediana. Sono lo stesso valore chiamato in due modi.

IL CONFRONTO FINALE

	Moda	Mediana	Media aritmetica
Che cos'è	la modalità più frequente	il valore che bipartisce la distribuzione	il valore che conserva la somma
Famiglia	media lasca	media lasca	media analitica
Usa tutti i dati?	no	no	**sì**
Sensibile agli estremi?	no	no	**sì**
Si può calcolare su un carattere qualitativo?	**sì**	no	no
Proprietà notevole	indica dove i casi sono più addensati	**minimizza la somma degli scarti in valore assoluto**	minimizza la somma degli scarti al quadrato

Quando si usa quale — la regola pratica:

- **la moda**, quando interessa **il caso tipico**, o quando il carattere è qualitativo e le altre due non esistono;
- **la mediana**, quando la distribuzione è **asimmetrica** o contiene valori estremi: redditi, patrimoni, tempi di attesa;
- **la media aritmetica**, quando interessa **il totale** e la distribuzione è ragionevolmente simmetrica.

LE DOMANDE D'ORALE, CON LE RISPOSTE GIÀ FORMULATE

1. Che cos'è la mediana?

> *«È l'indice di posizione che, in una distribuzione ordinata in senso crescente o decrescente, bipartisce la distribuzione lasciando metà dei casi a sinistra e metà a destra. È una media lasca, perché non usa tutti i valori ma solo la posizione centrale — e per questo è robusta rispetto ai valori estremi.»*

2. Come si trova con un numero pari di osservazioni?

> *«I posti centrali diventano due, e si assume come mediana la media aritmetica delle due intensità che li occupano. Può quindi risultare un valore che non compare fra i dati osservati.»*

3. Che cos'è la classe modale quando le classi hanno ampiezza diversa?

> *«Non è la classe con la frequenza più alta: è quella con la densità di frequenza più alta, cioè il rapporto fra la frequenza della classe e la sua ampiezza. Altrimenti si premierebbe una classe solo perché è più larga.»*

4. Perché sui redditi si usa la mediana?

> *«Perché la distribuzione dei redditi è fortemente asimmetrica. La media aritmetica usa tutti i valori e viene trascinata verso l'alto da pochi redditi molto elevati; la mediana guarda solo chi sta a metà della graduatoria e non ne risente. La mediana descrive l'italiano tipico, la media no.»*

5. Qual è la proprietà più importante della mediana?

> *«Che la somma dei valori assoluti degli scarti dalla mediana è minima: nessun altro valore rende quella somma più piccola. È il corrispettivo, in valore assoluto, della proprietà che la media aritmetica ha rispetto agli scarti al quadrato.»*

6. Quanti sono i quartili?

> *«Tre, e il secondo coincide con la mediana. In generale, per dividere una distribuzione in k parti servono k − 1 valori: due terzili, tre quartili, nove decili, novantanove centili.»*

LE SEI COSE DA RICORDARE

1. **Moda e mediana sono medie lasche**: non usano tutti i dati, e per questo **sono robuste**.
2. **La moda è l'unica** che funziona anche sui caratteri qualitativi.
3. **Classi di ampiezza diversa → densità di frequenza**, non frequenza. Nel manuale la classe con 148 aziende **non** è la classe modale.
4. **Mediana**: si ordina, si trova il posto centrale, e se le osservazioni sono pari si fa la media dei due centrali.
5. **Dentro la classe mediana si avanza in proporzione** — ed è una **stima**, perché si assume la distribuzione uniforme dentro la classe.
6. **La mediana minimizza la somma degli scarti in valore assoluto**; la media aritmetica minimizza quella degli scarti al quadrato. **Qui sta tutta la differenza fra le due.**