La variabilità

Manuale, cap. 1, §6, pp. 280-287. Spiegata dall'inizio, con un solo esempio portato fino in fondo.

---

1. Perché esiste tutto questo capitolo

Due uffici della stessa amministrazione. Giorni impiegati a pagare cinque fatture:

						Media
Ufficio A	43	44	45	46	47	**45**
Ufficio B	10	20	45	70	80	**45**

Stessa identica media: 45 giorni. E sono due uffici completamente diversi.

Nell'ufficio A un fornitore sa che verrà pagato in un mese e mezzo, punto. Nell'ufficio B può essere pagato in dieci giorni o in ottanta, ed è una lotteria. **Se fossi un fornitore, la media non ti direbbe nulla di ciò che ti interessa.**

> **Questa è l'intera ragione del §6.** La media risponde alla domanda *dove stanno i dati*. Ma due distribuzioni possono stare nello stesso posto ed essere opposte. Serve una seconda domanda: **quanto sono sparsi?**

Il manuale la definisce così: gli indici di variabilità sono

> **quantità atte a misurare la tendenza di un fenomeno ad assumere diverse modalità quantitative.**

Tradotto: **misurano quanto i dati si discostano fra loro invece di assomigliarsi.**

---

2. La mappa: tre modi diversi di misurare la dispersione

Prima degli strumenti, **la logica**. Il manuale (p. 269) organizza la famiglia così, e se tieni questa mappa non ti perdi più.

	L'idea	Gli strumenti
A. Misure di posizione	guardo **solo due punti** della distribuzione	campo di variazione, differenza interquartilica
B. Dispersione intorno a una media	misuro **quanto ogni dato dista dal centro**	scostamenti semplici medi, devianza, varianza, scarto quadratico medio
C. Disuguaglianza fra i dati	confronto **ogni dato con tutti gli altri**	differenze medie

A è economico ma grossolano. B è il cuore del capitolo. C risponde a una domanda leggermente diversa. Vediamoli in quest'ordine.

---

3. Famiglia A — guardare solo due punti

Il campo di variazione

> **È la differenza fra l'intensità massima e l'intensità minima.**

Nel nostro esempio: **A = 47 − 43 = 4 giorni. B = 80 − 10 = 70 giorni.**

Già questo separa i due uffici, e costa un secondo di calcolo. Ma il manuale ne elenca **tre difetti**, ed è la domanda d'orale tipica:

1. **tiene conto solo dei due valori estremi**, senza considerare la struttura interna della distribuzione;
2. **è influenzabile da valori estremi anormali** — un solo caso stravagante lo gonfia;
3. **non è determinabile quando la classe iniziale e quella finale sono aperte** (del tipo «oltre 80 anni»: se non sai dove finisce, non puoi fare la sottrazione).

La differenza interquartilica

> **È la differenza fra il terzo e il primo quartile: $Q_3 - Q_1$.**

Nell'intervallo che individua cade il 50% dei casi — cioè la metà centrale della distribuzione.

Il vantaggio sul campo di variazione: tagliando via il 25% più basso e il 25% più alto, **butta fuori proprio i valori estremi** che disturbavano. È l'equivalente, per la variabilità, di ciò che la mediana è per la posizione: una misura **robusta**.

Il difetto, che il manuale dichiara: al pari del campo di variazione, **anche questo indice non tiene conto della struttura interna** della distribuzione. Guarda due punti, sia pure due punti meglio scelti.

---

4. Famiglia B — il cuore: la distanza dal centro

Qui si cambia filosofia. **Non più due punti: tutti.**

L'idea, e il problema che nasce subito

L'idea naturale è questa: per ogni dato calcolo **quanto dista dalla media** (questo si chiama **scarto**), e poi faccio la media di queste distanze.

Proviamo sull'ufficio A, la cui media è 45:

Dato	**43**	**44**	**45**	**46**	**47**
Scarto dalla media	−2	−1	0	+1	+2

Sommiamo gli scarti: −2 −1 + 0 + 1 + 2 = **0**.

Proviamo sull'ufficio B: −35, −25, 0, +25, +35. Somma: **0**.

> **Non è un caso: viene sempre zero.** È una proprietà della media aritmetica — è il punto di equilibrio, quindi ciò che sta sotto compensa esattamente ciò che sta sopra.
>
> **Quindi la strada ovvia non funziona**, e tutta la famiglia B nasce da un unico problema pratico: **come rendo positivi gli scarti**, in modo che non si annullino?

Ci sono due risposte, e sono le due metà del capitolo.

La risposta	**Dove porta**
prendo il valore assoluto (ignoro il segno)	→ gli **scostamenti semplici medi**
li elevo al quadrato	→ **devianza, varianza, scarto quadratico medio**

4a. La prima risposta: il valore assoluto

Scostamento semplice medio dalla media aritmetica (§6.3)

> **È la media aritmetica — semplice o ponderata — dei valori assoluti degli scarti dalla media aritmetica.**

Sul nostro esempio:

- **Ufficio A**: gli scarti in valore assoluto sono 2, 1, 0, 1, 2. Somma 6, divisa per 5 → **1,2 giorni**.
- **Ufficio B**: 35, 25, 0, 25, 35. Somma 120, divisa per 5 → **24 giorni**.

Si legge così: *in media, un ufficio A si discosta di 1,2 giorni dal proprio tempo medio; un ufficio B di 24.* Una frase che si capisce.

La differenza rispetto alla famiglia A, e il manuale la sottolinea: a differenza del campo di variazione e della differenza interquartilica, **questo indice tiene conto di tutte le intensità** della distribuzione.

Scostamento semplice medio dalla mediana (§6.4)

Identico, ma gli scarti si misurano **dalla mediana** invece che dalla media.

> **E qui torna la proprietà che abbiamo visto ieri.** Ricordi? *La somma dei valori assoluti degli scarti dalla mediana è minima.*
>
> **Conseguenza diretta: lo scostamento semplice medio dalla mediana è sempre minore o uguale a quello dalla media.** Non è una curiosità: è *il motivo* per cui il manuale dedica un paragrafo a ciascuno. Saperlo collegare, all'orale, vale molto.

Nota operativa valida per entrambi: quando i dati sono raggruppati in classi, **si sostituisce a ciascun valore il valore centrale della classe**.

4b. La seconda risposta: il quadrato

Questa è la strada che la statistica ha scelto davvero, e il manuale la tratta in due paragrafi — **in un ordine che conviene invertire** per capirla.

Devianza (§6.6)

> **È la somma — semplice o ponderata — dei quadrati degli scarti fra le singole intensità e la media aritmetica.**

Sul nostro esempio:

- **Ufficio A**: 4 + 1 + 0 + 1 + 4 = **10**
- **Ufficio B**: 1225 + 625 + 0 + 625 + 1225 = **3.700**

È una somma, quindi **cresce col numero di osservazioni**: cento uffici tranquilli avrebbero una devianza più grande di cinque uffici caotici. Da sola non si può confrontare.

Varianza (§6.6)

> **È il rapporto fra la devianza e la numerosità N del collettivo.**

Cioè: **la devianza divisa per quanti sono**. È la devianza resa confrontabile.

- **Ufficio A**: 10 / 5 = **2**
- **Ufficio B**: 3.700 / 5 = **740**

Il problema della varianza, che il manuale dichiara: è **espressa nel quadrato dell'unità di misura** del fenomeno. La varianza dell'ufficio A è «2 giorni al quadrato». **Giorni al quadrato non significa niente**, non si può dire a voce e non si può spiegare a un dirigente.

Scarto quadratico medio (§6.5)

> **È la media quadratica degli scostamenti fra le singole intensità e la media aritmetica.** Ed è, operativamente, **la radice quadrata della varianza**.

- **Ufficio A**: √2 = **1,41 giorni**
- **Ufficio B**: √740 = **27,2 giorni**

Ed eccoci tornati in giorni. Questo è tutto il senso della radice: **riporta la misura nell'unità originaria**, e quindi la rende dicibile.

> **La catena da raccontare all'orale, ed è la risposta completa:**
>
> *«Si parte dagli scarti dalla media, che però sommati danno sempre zero. Si elevano al quadrato per renderli positivi, e la loro somma è la **devianza**. La devianza dipende da quante osservazioni ci sono, quindi la si divide per N e si ottiene la **varianza**. La varianza però è espressa nel quadrato dell'unità di misura, quindi se ne estrae la radice e si ottiene lo **scarto quadratico medio**, che è nella stessa unità del fenomeno ed è l'indice che si usa in pratica.»*
>
> **Quattro frasi, nessuna formula, e hai spiegato metà del capitolo.**

Due precisazioni che il manuale aggiunge e che valgono punti:

- **lo scarto quadratico medio è un indice di variabilità assoluta**, perché è espresso nella stessa unità di misura dei dati;
- c'è un legame elegante con le medie che già conosci: **la varianza è la differenza fra il quadrato della media quadratica e il quadrato della media aritmetica.** È la formula «semplificata» che il manuale usa per non dover calcolare tutti gli scarti uno per uno — e nell'**Esempio 15** (altezze di 125 atleti) la applica proprio così: 34.331,85 − 34.276,82 = **55,03**.

Una nota tecnica da riconoscere, non da saper fare: quando i dati sono raggruppati in classi si usano i valori centrali, e questo introduce un'approssimazione; per correggerla si applica la **correzione di Sheppard**. Ti basta sapere che esiste e a che cosa serve.

---

5. Assoluto e relativo — la distinzione che vale un voto

Siamo arrivati al punto più importante dopo la catena devianza-varianza-s.q.m.

	Che cosa sono	Il limite / il pregio
indici assoluti	espressi **nella stessa unità di misura** del fenomeno	descrivono bene **una** distribuzione, ma **non permettono confronti** fra fenomeni diversi
indici relativi	ottenuti **rapportando** un indice assoluto a un altro parametro: sono **numeri puri**, senza unità di misura	**servono proprio a confrontare**

Il problema, con un esempio. Lo scarto quadratico medio dei giorni di pagamento è in giorni; quello degli stipendi è in euro. **Quale dei due fenomeni è più variabile?** La domanda, così, non ha risposta: stai confrontando giorni con euro.

Il coefficiente di variabilità

> **È il rapporto fra lo scarto quadratico medio e la media aritmetica.** È un **numero puro** e **si esprime generalmente in percentuale**.

Sul nostro esempio:

	s.q.m.	media	coefficiente di variabilità
Ufficio A	1,41	45	**3,1%**
Ufficio B	27,2	45	**60,4%**

Adesso i numeri parlano da soli: nell'ufficio A la dispersione vale il 3% del tempo medio, nell'ufficio B il 60%. E questi due numeri si possono confrontare **con qualunque altro fenomeno**, misurato in qualunque unità.

> **La frase d'orale**: *«Il coefficiente di variabilità è il rapporto fra lo scarto quadratico medio e la media aritmetica. Essendo un numero puro, permette di confrontare la variabilità di fenomeni espressi in unità di misura diverse, cosa che gli indici assoluti non consentono.»*

Gli indici rapportati al massimo (§6.8)

C'è un secondo modo di costruire un indice relativo: **rapportare l'indice assoluto al valore che avrebbe nella distribuzione di massima variabilità** — quella che il manuale chiama **distribuzione massimante**.

Il risultato è un indice che varia fra 0 e 1: vale **0 se la variabilità è nulla** e **1 se è massima**.

Ti basta sapere **l'idea** — misurare la variabilità osservata come frazione della massima possibile — e che esiste **per lo s.q.m.** e **per la differenza media senza ripetizione**. I passaggi algebrici non sono materia da orale.

La standardizzazione — un ponte verso i capitoli successivi

Il manuale, chiudendo il §6.5, introduce una cosa che sembra minore e invece tornerà in continuazione: **gli scarti standardizzati**.

> Si prende lo scarto di un dato dalla media e **lo si divide per lo scarto quadratico medio**.

Che cosa ottieni: un numero che dice **quanti scarti quadratici medi quel dato è lontano dalla media**. Un ufficio che paga in 72 giorni, in un contesto con media 45 e s.q.m. 27, sta **a un s.q.m. dalla media**: tanto, ma non eccezionale.

> **Perché segnartelo adesso.** È il meccanismo su cui si reggeranno la distribuzione normale (cap. 3), gli intervalli di confidenza (cap. 4) e i test (cap. 5). **Standardizzare significa smettere di misurare in giorni o in euro e cominciare a misurare in «quanto è insolito».**

---

6. Famiglia C — la disuguaglianza fra i dati (§6.7)

Un'idea diversa dalle precedenti, e il manuale la tiene separata apposta.

Finora abbiamo sempre misurato **la distanza dei dati da un centro**. Le **differenze medie** fanno un'altra cosa: **confrontano i dati a due a due, fra loro**, senza passare da nessuna media.

> **La differenza media è un indice assoluto di variabilità che misura la disuguaglianza media fra le intensità di una variabile statistica, ottenuta confrontando tutti i termini a due a due.**

E ne esistono due versioni, che si distinguono per un dettaglio:

	Il confronto di un termine con se stesso	**Quanti confronti**
con ripetizione	**incluso**	N^2
senza ripetizione	**escluso**	$N^2 - N = N(N-1)$

Perché la distinzione esiste, in parole. Confrontare un valore con se stesso dà sempre zero. Quei confronti nulli sono N, e includerli o no cambia il denominatore — quindi cambia il risultato. **Con ripetizione il risultato è più piccolo**, perché gli N zeri «diluiscono» la media.

> **Il senso di questa famiglia**: risponde alla domanda *«quanto sono diversi fra loro?»* invece di *«quanto sono lontani dal centro?»*. Sono due domande parenti ma non identiche — ed è questa la ragione per cui il manuale distingue fin da p. 269 le misure di **dispersione** da quelle di **disuguaglianza**.

---

7. La concentrazione (§6.9) — un caso a parte

Il manuale la presenta come **un aspetto della variabilità**, ma con una limitazione netta che è **la cosa da ricordare**:

> **La concentrazione ha senso solo per caratteri additivi e trasferibili** — come il reddito o il capitale azionario — **vale a dire se la sua intensità globale o una sua parte possono essere possedute da una o più unità.**

Tradotto: ha senso chiedersi *quanto del totale è in mano a pochi?* solo se quel totale è una cosa che si può ammucchiare e passare di mano. **Il reddito sì, l'altezza no**: non esiste il «totale delle altezze» che qualcuno possa possedere.

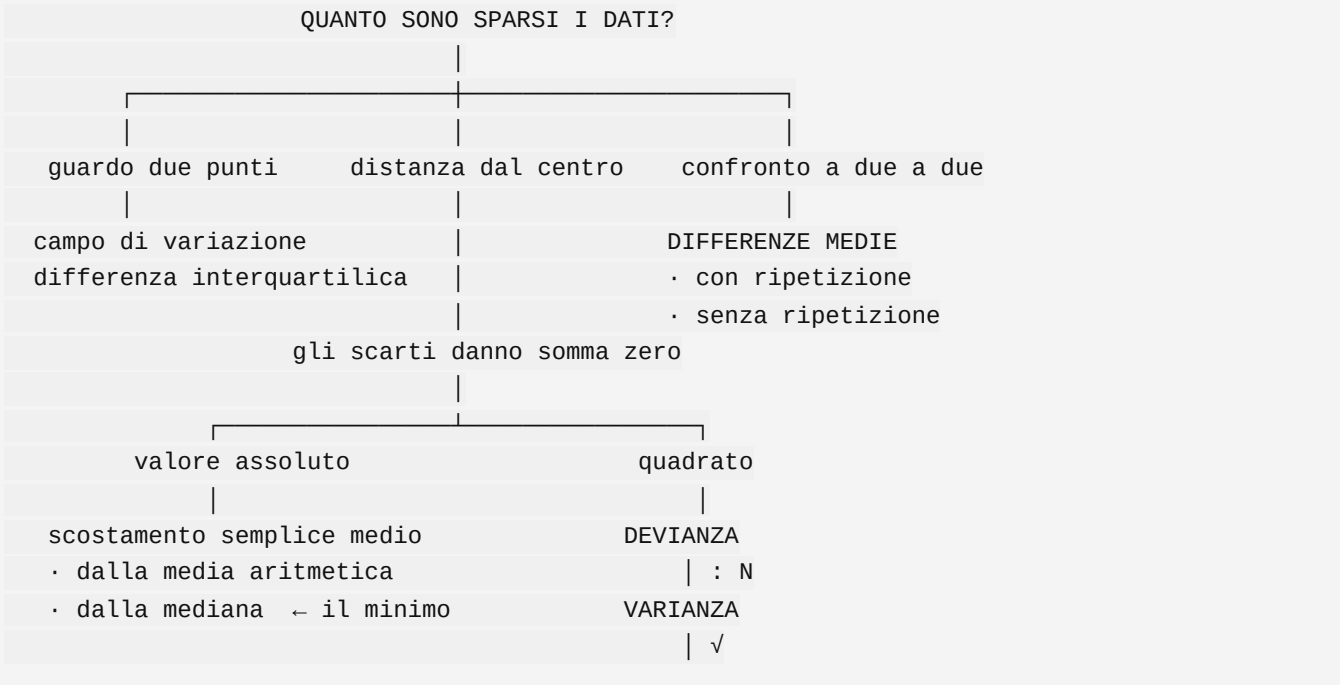
E il concetto opposto:

> **Un carattere si dice equidistribuito se non è concentrato in assoluto**, vale a dire se determinate frazioni del suo ammontare appartengono a uguali frazioni di unità statistiche.

Cioè: il 10% delle unità possiede il 10% del totale, il 20% ne possiede il 20%, e così via. **Perfetta uguaglianza.**

Gli strumenti sono il **rapporto di concentrazione** e **l'indice di Gini**, che il manuale distingue (il secondo non tiene conto di un elemento di cui tiene conto il primo). Per l'orale basta **sapere che misurano quanto il totale è distribuito in modo diseguale**, e il vincolo dei caratteri **additivi e trasferibili**, che è la vera domanda da pignolo.

L'ALBERO COMPLETO, IN UNA PAGINA



```
                    SCARTO QUADRATICO MEDIO
                              | : media
                  COEFFICIENTE DI VARIABILITÀ
                       (numero puro)
```

LE OTTO COSE DA RICORDARE

1. **La media non basta**: due distribuzioni con la stessa media possono essere opposte. La variabilità è la seconda domanda.
2. **Campo di variazione e differenza interquartilica guardano solo due punti** e non vedono la struttura interna. Il campo di variazione, in più, **non esiste se le classi estreme sono aperte**.
3. **Gli scarti dalla media sommati danno sempre zero.** Tutto il resto del capitolo nasce da questo problema.
4. **Due vie d'uscita**: valore assoluto → scostamenti semplici medi; quadrato → devianza, varianza, s.q.m.
5. **La catena**: scarti → al quadrato → **devianza** → diviso N → **varianza** → radice → **scarto quadratico medio**.
6. **La varianza è in unità al quadrato e non si può dire a voce**; lo scarto quadratico medio sì. È per questo che si fa la radice.
7. **Assoluto vs relativo**: gli assoluti descrivono, i relativi **confrontano**. Il **coefficiente di variabilità** è s.q.m. diviso media, è un numero puro e si esprime in percentuale.
8. **La concentrazione vale solo per caratteri additivi e trasferibili.**