Blocco 2 da ripetere — La regressione

Su 37 domande di econometria uscite all'orale, una ventina riguardano la regressione. È il blocco che decide il voto della materia.

Undici domande, con la risposta da dire a voce. Stesse regole del blocco 1: leggi la domanda, chiudi il foglio, rispondi **ad alta voce**, poi confronta con i **pezzi che devono esserci**.

> **Due avvertenze sulle fonti.** Le risposte 3 e 11 trattano argomenti che **non ho trovato nelle parti 1 e 2 della scansione**: sono econometria standard e sono fra le domande uscite, ma vanno verificate sulla parte del manuale non ancora caricata. Tutto il resto è sul libro, e indico la pagina.

---

1. Che cos'è un modello econometrico e a cosa serve per la valutazione delle politiche?

(domanda 113)

> Un modello è **una rappresentazione formale delle conoscenze su un fenomeno**: non una riproduzione esatta della realtà, ma **una versione semplificata**, scritta come una o più equazioni.
>
> In un modello econometrico si distinguono le variabili **endogene**, che il modello spiega, da quelle **esogene**, che prende come date. E si distingue una **parte sistematica**, cioè ciò che il modello spiega, da una **parte stocastica**, l'errore, cioè ciò che non spiega.
>
> Per la valutazione delle politiche serve a rispondere alla domanda centrale: **quanta parte del risultato osservato è attribuibile all'intervento e quanta a tutto il resto.** Senza un modello si confronta il prima con il dopo e si attribuisce alla politica anche ciò che sarebbe accaduto comunque.

I pezzi: rappresentazione formale e semplificata; endogene/esogene; sistematica/stocastica; attribuire l'effetto all'intervento.

---

2. Che cos'è la regressione lineare multipla, e perché non basta quella semplice?

(domanda 118)

> È il modello che spiega la variabile dipendente con **più variabili esplicative contemporaneamente**, invece di una sola.
>
> Serve perché **nella realtà le cause sono quasi sempre più d'una**. Se spiego i tempi di pagamento dei comuni solo con il personale in ragioneria, attribuisco al personale anche l'effetto della dimensione del comune, del

> software, degli arretrati.
>
> **E qui sta la differenza che conta nell'interpretazione**: nella regressione multipla ogni coefficiente si legge **«a parità delle altre variabili»**. Dice l'effetto di quella variabile **tenendo ferme le altre** — cioè depurato dal loro contributo.
>
> **È esattamente il problema della valutazione delle politiche**: distinguere l'effetto dell'intervento da quello dei fattori che agiscono insieme a lui.

I pezzi: più esplicative insieme; «a parità delle altre»; il legame con la valutazione.

---

3. Che cosa accade se si inserisce una variabile irrilevante nel modello?

(domanda 119) — ⚠️ da verificare sulla parte del manuale non caricata

> Inserire una variabile che **non c'entra** non rende le stime sbagliate in media: **gli stimatori restano non distorti**. Il danno è un altro: **ne aumenta la varianza**, cioè **le stime diventano meno precise**, con errori standard più grandi.
>
> In più **l'R quadro sale comunque**, anche se la variabile è inutile — e questo è ingannevole, perché dà l'impressione di aver migliorato il modello. Per questo si guarda **l'R quadro corretto**, che tiene conto del numero di variabili inserite.
>
> **Il caso opposto è peggiore**: se si **omette** una variabile rilevante, le stime diventano **distorte**, perché il suo effetto viene attribuito alle variabili rimaste.

I pezzi: irrilevante → non distorte ma meno precise; R quadro sale comunque → R quadro corretto; omettere è peggio che aggiungere.

---

4. Che cosa indica la proprietà BLUE degli stimatori?

(domande 124 e 173 — manuale p. 361)

> **BLUE** sta per **Best Linear Unbiased Estimator**, ed è il contenuto del **teorema di Gauss-Markov**, che il manuale enuncia così: *sotto le ipotesi classiche del modello di regressione lineare, gli stimatori dei minimi quadrati sono **lineari**, **non distorti** e **i più efficienti** nella classe degli stimatori lineari e non distorti.*
>
> Le tre parole significano: — **lineari**: sono combinazioni lineari delle osservazioni; — **non distorti** *(unbiased)*: **in media colpiscono il valore vero**, non sbagliano sistematicamente in una direzione; — **i più efficienti** *(best)*: fra tutti quelli che hanno le prime due proprietà, sono quelli con **la varianza più piccola**, cioè i più precisi.
>
> **È la giustificazione teorica dell'uso dei minimi quadrati**: non si usano perché sono comodi, ma perché sotto quelle ipotesi sono i migliori disponibili.

> **E il punto critico da aggiungere**: vale **sotto le ipotesi classiche**. Se le ipotesi cadono — eteroschedasticità, autocorrelazione, endogeneità — **gli stimatori OLS smettono di essere BLUE**.

I pezzi: Best Linear Unbiased Estimator; Gauss-Markov; le tre parole tradotte; vale solo sotto le ipotesi.

---

5. Che cosa significa uno stimatore con grande varianza?

(domanda 123)

> Significa che **la stima è instabile**: se rifacessi lo stesso studio su un altro campione, otterrei un valore sensibilmente diverso.
>
> La conseguenza pratica è che **l'errore standard è grande** e **gli intervalli di confidenza sono ampi**: il dato esiste, ma **dice poco**, perché il valore vero potrebbe stare in un intervallo troppo largo per decidere qualcosa.
>
> **Da non confondere con la distorsione**: uno stimatore con grande varianza può essere perfettamente **non distorto** — in media colpisce il bersaglio, ma **il singolo colpo può finire lontano**.

I pezzi: instabilità fra campioni; errore standard e intervalli ampi; varianza ≠ distorsione.

---

6. Differenza fra distorsione e varianza di uno stimatore. Il trade-off.

(domanda 244)

> Sono **due modi diversi di sbagliare**.
>
> La **distorsione** *(bias)* è un errore **sistematico**: lo stimatore sbaglia **sempre nella stessa direzione**, e non migliora aumentando i dati. La **varianza** è un errore **di instabilità**: in media è giusto, ma **oscilla molto** da un campione all'altro.
>
> **L'immagine del bersaglio**: un tiratore distorto centra sempre lo stesso punto, ma fuori dal centro. Un tiratore con grande varianza sparge i colpi tutt'intorno al centro.
>
> **Il trade-off**: un modello **molto semplice** rischia la distorsione, perché trascura pezzi di realtà. Un modello **molto complesso** riduce la distorsione ma **aumenta la varianza**, perché insegue anche il rumore del campione. La scelta del modello è il punto di equilibrio fra i due errori.

I pezzi: sistematico vs instabile; l'immagine del bersaglio; semplice ↔ distorsione, complesso ↔ varianza.

---

7. Che cosa sono endogeneità e variabili strumentali?

(domande 128 e 222 — manuale pp. 440-441) — **la domanda più importante del blocco**

> Una delle ipotesi del modello è che **le variabili esplicative siano indipendenti dall'errore**: in quel caso si dicono **esogene**. Quando invece **esiste un legame fra i regressori e l'errore**, si ha **endogeneità dei regressori**, e **la stima del parametro non è più corretta né consistente**.
>
> Il manuale indica **tre cause**: — **l'omissione di un'altra variabile esplicativa**; — **errori di misurazione** delle variabili indipendenti; — **simultaneità** fra le variabili, o autocorrelazione nei modelli dinamici.
>
> **L'esempio del manuale per l'omissione**: si stima l'effetto dell'istruzione sul salario senza poter osservare **l'abilità individuale**, che non è misurabile. L'abilità finisce nell'errore ed è correlata con l'istruzione: il coefficiente dell'istruzione **si prende anche il merito dell'abilità**.
>
> **L'esempio per la simultaneità**: prezzo e quantità di un bene sono determinati **congiuntamente** dall'equilibrio fra domanda e offerta, e non si riesce a distinguere l'effetto dei due.
>
> **Il rimedio sono le variabili strumentali**, in inglese *instrumental variables*. Si cerca una variabile che soddisfi **tre condizioni**: — **rilevanza**: dev'essere **correlata con il regressore endogeno**; — **esogeneità**: dev'essere **incorrelata con i disturbi**; — **esclusione**: **non deve influenzare direttamente la variabile dipendente**.
>
> L'esempio del manuale: per l'offerta di un bene alimentare si usano i **fattori meteorologici**, che influenzano l'offerta ma **non la domanda**.

I pezzi: legame fra regressori ed errore; le tre cause; l'esempio istruzione-abilità; le tre condizioni con i loro nomi.

> **Perché è la domanda più importante**: l'endogeneità è **il motivo per cui correlazione non significa causalità**, ed è il problema centrale della valutazione d'impatto. È il punto in cui econometria e bando si toccano.

---

8. Quando una stima non si generalizza a dati nuovi? Che cos'è l'analisi di robustezza?

(domande 129, 273)

> Una stima **in-sample** misura quanto il modello si adatta **ai dati con cui è stato costruito**. Non garantisce nulla sulla capacità di funzionare su dati nuovi.
>
> Il motivo è il **sovra-adattamento**, l'*overfitting*: un modello troppo ricco finisce per **inseguire le particolarità di quel campione** — il rumore — invece della relazione vera. Su quei dati va benissimo; su altri crolla.
>
> Per verificarlo si **divide il campione**: una parte serve alla stima, una parte, mai vista dal modello, serve alla verifica. Oppure si usa la **convalida incrociata**, la *cross-validation*, che ripete questa divisione più volte.
>
> L'**analisi di robustezza** fa una cosa parallela: **si rifà la stima cambiando qualcosa** — il periodo, il sottogruppo, le variabili di controllo, la forma funzionale — e si guarda **se il risultato regge**. Un risultato che cambia segno al primo controllo non è un risultato.

I pezzi: in-sample ≠ previsione; overfitting; train/test e cross-validation; robustezza = cambiare qualcosa e vedere se tiene.

9. Quali differenze esistono fra modello teorico e modello stimato?

(domanda 130)

> Il **modello teorico** è la relazione che la teoria economica ipotizza fra le grandezze: contiene **parametri incogniti**, indicati con lettere greche, e riguarda **l'intera popolazione**.
>
> Il **modello stimato** è quello che si ottiene **applicando un metodo di stima a un campione**: al posto dei parametri veri ci sono le **stime**, cioè numeri calcolati sui dati.
>
> **La differenza fondamentale è che il modello teorico è uno, le stime cambiano**: su un altro campione otterrei numeri diversi. Per questo accanto a ogni stima si riporta **l'errore standard**, che ne dichiara l'incertezza.
>
> E c'è una differenza di ruolo: **il modello teorico dice che cosa ci si aspetta e perché**; il modello stimato dice **che cosa i dati effettivamente mostrano**. Confrontarli è il modo in cui una teoria viene messa alla prova — ed è, in fondo, **il mestiere dell'econometria**.

I pezzi: parametri veri vs stime; popolazione vs campione; le stime cambiano → errore standard; il confronto è la verifica della teoria.

---

10. Che cosa significa cambiare la scala di una variabile?

(domanda 120)

> Significa **esprimere la stessa grandezza in un'unità di misura diversa**: il reddito in migliaia di euro invece che in euro, la spesa in milioni invece che in unità.
>
> **L'effetto è solo sui numeri, non sulla sostanza.** Il coefficiente cambia in modo proporzionale — se esprimo il reddito in migliaia, il coefficiente si moltiplica per mille — ma **l'R quadro non cambia**, **la significatività non cambia**, e **le conclusioni restano identiche**.
>
> **È l'errore tipico di chi legge una tabella senza guardare l'unità di misura**: due coefficienti di grandezza molto diversa possono dire esattamente la stessa cosa. **Prima di commentare un coefficiente bisogna sempre chiedersi in che unità sono espresse le variabili.**

I pezzi: stessa grandezza, unità diversa; il coefficiente cambia proporzionalmente, le conclusioni no; guardare sempre l'unità di misura.

---

11. Che cosa sono i modelli a effetti fissi e a effetti casuali?

(domande 125 e 126) — ⚠️ da verificare sulla parte del manuale non caricata

> Sono due modi di trattare i **dati panel**, cioè i dati che seguono **più soggetti nel tempo** — per esempio cento comuni osservati per cinque anni.
>
> Il problema che risolvono è **l'eterogeneità non osservata**: ogni comune ha caratteristiche proprie e stabili — la cultura amministrativa, la qualità della macchina organizzativa — che **influenzano il risultato ma non si riescono a misurare**.
>
> Nel modello a **effetti fissi** si assegna a ciascun soggetto **un termine proprio**, che cattura tutto ciò che in lui è stabile nel tempo. In pratica **si confronta ogni comune con se stesso** nei vari anni, eliminando le sue caratteristiche fisse. Si usa quando quelle caratteristiche **possono essere correlate con le variabili esplicative**.
>
> Nel modello a **effetti casuali** l'eterogeneità è trattata come una **componente casuale**, che si assume **incorrelata con le variabili esplicative**. È più efficiente, ma **solo se quell'ipotesi regge**.
>
> **La scelta fra i due dipende da quell'ipotesi**: se l'eterogeneità individuale è correlata con i regressori, gli effetti casuali danno stime distorte e servono gli effetti fissi.

I pezzi: dati panel; eterogeneità non osservata; fissi = confronto del soggetto con se stesso; casuali = più efficienti ma richiedono incorrelazione.

La frase che tiene insieme tutto il blocco

Se dovessi riassumere l'intero capitolo in una frase da dire alla commissione:

> *«La regressione serve a misurare quanto una variabile incide su un'altra. I minimi quadrati danno la stima migliore possibile — **sotto certe ipotesi**. Il mestiere dell'econometrista non è calcolare quella stima: è **sapere quando quelle ipotesi cadono, e che cosa fare allora**.»*

Tutte le domande di questo blocco sono variazioni su quella frase.